2025 年（第 18 届）
中国大学生计算机设计大赛

大数据实践赛作品报告

作品编号：2025052564

作品名称：格幻致知--通用型 LLM 全幻觉检测与分析系统

填写日期：2025 年 5 月 3 日

填写说明：

1、正文、标题格式已经在本文中设定，请勿修改；标题#的快捷键为“Ctrl+#”，正文快捷键为“Ctrl + 0”；

2、本文档应结构清晰，突出重点，适当配合图表，描述准确，不易冗长拖沓；

3、提交文档时，以 PDF 格式提交；

4、本文档内容是正式参赛内容的组成部分，务必真实填写。如不属实，将导致奖项等级降低甚至终止本作品参加比赛；

5、如果使用大模型，请参赛者在提交的作品中详细说明大模型在研究或创作中的具体使用方式以及优化的开发模块。

目 录

第 1 章 作品概述.....1
1.1 创意来源和产生背景.....1
1.2 用户群体.....1
1.3 主要功能与特色.....1
1.4 应用价值和推广前景.....1

第 2 章 问题分析.....2
2.1 问题来源.....2
2.1.1 幻觉问题背景及起因.....2
2.1.2 幻觉问题案例以及危害.....3
2.2 现有解决方案.....5
2.3 本作品要解决的痛点问题.....7
2.3.1 痛点问题一：语义表示不足导致检测精度低.....7
2.3.2 痛点问题二：不一致性检测方法难以兼顾高确定性幻觉.....8
2.3.3 痛点问题三：幻觉检测结果缺乏可解释性.....8
2.4 解决问题的思路.....9
2.4.1 作品功能分析.....9
2.4.2 检测指标.....9
2.4.3 数据集.....10

第 3 章 技术方案.....17
3.1 忠实性幻觉检测模块.....18
3.1.1 语义图转化.....19
3.1.2 双模态编码.....22
3.1.3 句子级忠实性分类.....25
3.2 事实性幻觉检测.....25
3.2.1 流程导向模块.....27
3.2.2 语义熵.....31
3.2.3 单命题回答语义熵计算.....32
3.2.4 多命题回答语义熵计算.....38
3.2.5 知识库.....44
3.3 幻觉解释模块.....47
3.3.1 忠实性上下文分析解释.....48
3.3.2 基于原子事实的语义采样对比解释.....49
3.3.3 基于原子事实的知识冲突对比解释.....50

第 4 章 系统实现.....51
4.1 系统功能实现.....51
4.2 系统用户界面.....52
4.3 数据来源.....57
4.4 数据训练.....58

4.5 改进过程 58
第 5 章 测试分析 59
5.1 测试数据集 59
5.2 测试过程 59
5.3 测试结果分析 60
第 6 章 作品总结 63
6.1 作品特色与创新点 63
6.1.1 双模态图-文本联合编码架构 63
6.1.2 内外部知识融合的迭代增强检测机制 64
6.1.3 多模块协同的少样本驱动幻觉解释架构 64
6.2 算法基础 65
6.3 应用推广 65
6.4 作品展望 66
6.5 技术路线方面 66
6.6 工作量方面 67
6.7 数据和测试效果方面 67
参考文献 67

第1章 作品概述

1.1 创意来源和产生背景

大语言模型 (LLM) 的崛起标志着自然语言处理领域的范式变革，2025 年春节期间 DeepSeek 的爆发式普及进一步推动了 LLM 的大众化应用。然而，受限于数据的局限性、概率生成的固有特性以及事实核查能力的缺失，LLM 呈现出生成幻觉的倾向。针对该问题，许多研究人员开发了高效的幻觉检测模型。但现有研究存在三大局限：一，这些模型大多考虑利用不一致性检测幻觉，未能有效捕捉高置信度幻觉；二，缺乏针对于多类型的幻觉检测系统；三，检测结果缺乏可解释性。因此，本作品构建了一套通用型 LLM 全幻觉检测与分析系统，通过多模块协同架构设计，实现了对上述问题的系统性解决。

1.2 用户群体

本系统主要面向三类核心用户群体：依赖 LLM 解决日常问题但需要内容准确性和上下文一致性的普通用户，专注模型研发且重视幻觉检测技术的开发者，以及医疗、教育、政府等领域对大模型可靠性与真实性有较高要求的组织与个人。

1.3 主要功能与特色

作品主要功能包括多模型接入与使用、自动全幻觉检测、幻觉句子定位和幻觉成因分析。本作品特色包含四个方面，一是跨模型适配，采用统一黑盒检测框架实现跨模型兼容，支持多源 LLM API 密钥整合；二是通过双模态编码结构实现细粒度的忠实性幻觉检测；三是通过互补增强幻觉检测模块，结合语义熵与知识库检索，提高事实性幻觉检测的准确性和全面性；四是通过幻觉解释模块，对检测出的幻觉句子进行用户友好解释，让用户理解产生幻觉的原因。

1.4 应用价值和推广前景

本作品的应用价值在于能够使用户自由选择大模型进行交互，并在检测幻觉

后获得清晰的解释，有助于用户快速判断信息的可靠性，提高用户对错误信息修改的可能性，减少幻觉导致的信息误导，维护网络环境的稳定有序。

推广前景方面，本项目具有广阔的发展空间。随着 LLM 的快速迭代和应用场景的持续拓展，本项目有望获得对生成内容可靠性要求较高的行业（医疗、法律等）、研究机构、以及个人用户的青睐与采用。

第2章 问题分析

2.1 问题来源

2.1.1 幻觉问题背景及起因

随着 LLM 技术的飞速发展，以 ChatGPT[2]、DeepSeek[58]为代表的先进模型已被广泛应用于信息检索、自动化问答和文本生成等领域，展现出强大的语言推理与生成能力，推动了信息获取范式的深刻变革。然而，LLM 在处理多样化任务时虽表现出色，其生成内容却存在显著的真实性缺陷。尤为突出的是大语言模型幻觉问题 (Large Language Model Hallucination)，即**模型生成看似合理但实际错误或虚构的内容**。幻觉问题日益凸显，成为制约其可信度和实用性的关键瓶颈。

值得注意的是，现有的研究中普遍将幻觉划分为两个类型（如图 2-1 所示）：**忠实性幻觉** (Faithfulness Hallucination)和**事实性幻觉**(Factuality Hallucination)[17]。忠实性幻觉是指模型生成的内容与用户的指令或上下文不一致，事实性幻觉是指模型生成的内容与可验证的现实世界事实不一致。举例来说：用户要求模型从指定的上下文指令中提取新闻的细节，但模型输出的细节却有悖于用户的上下文信息，这样的现象就称为忠实性幻觉；此外，用户问 LLM：“第一个在月球上行走的人是谁”，而模型回答“Charles Lindbergh 在 1951 年月球先驱任务中第一个登上月球”，但实际上第一个登上月球的人是 Neil Armstrong，这样的现象称为事实性幻觉。

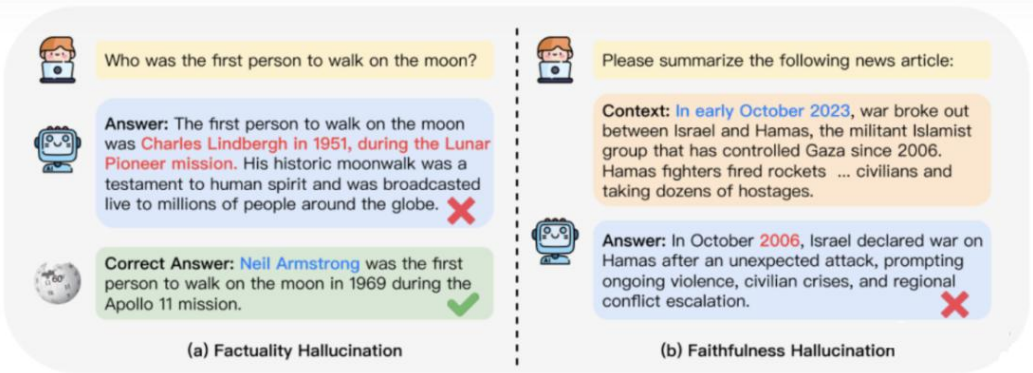


图 2-1 幻觉分类示例

幻觉问题的产生是数据质量、训练机制和推理策略等多重因素交织作用的结果。LLM 的训练数据多源自互联网，其中包含大量不准确、偏颇甚至过时的信息，模型在无差别学习这些数据时，容易将其视为事实输出。在预训练阶段，语料的准确性和时效性参差不齐，导致模型习得过时或错误的事实；在微调阶段，训练数据的简单性或指令的复杂性可能导致模型生成不符合实际的回答。在推理过程中，LLM 依赖随机性和预测下一步词语的策略，虽能生成流畅文本，但在缺乏充分事实依据的情况下，容易生成看似合理却毫无根据的内容，进一步加剧幻觉现象。

中国工程院院士沈昌祥认为完全消除大模型“幻觉”等安全风险较难实现[64]。因此，研究和开发一种在大模型外部的可解释型幻觉检测系统对于提升 LLM 在实际应用中的可信度、安全性和稳定性具有重要意义和学术价值，更契合实际应用需求，为推动 LLM 的广泛应用提供关键技术支持。

2.1.2 幻觉问题案例以及危害

LLM 的幻觉问题带来了多方面的危害，尤其在依赖准确性和事实验证的应用中，不可靠的回复或冗余信息严重阻碍了 LLM 在各领域的应用。此外，幻觉的传播可能进一步加剧虚假信息的扩散，尤其在社交媒体和新闻领域，这会对社会信任、舆论导向和公共决策产生负面影响。

例如，2023 年 2 月 16 日，一则“浙江省杭州市政府 3 月 1 日取消机动车依尾号限行”的“新闻稿”在网上广泛传播。17 日，杭州警方证实该消息不实，并已介入调查。据媒体报道，16 日下午，杭州某小区业主群讨论 ChatGPT 时，一位业主开玩笑地尝试用其撰写杭州取消限行的新闻稿，并在群里直播了写作过程，还将文章发布在群内[65]。这篇“假新闻”行文严谨、措辞得当，且基本符合官方

通报格式，其他业主不明真相，随后截图转发，导致错误信息大规模传播。涉事业主后来在群里道歉（如图 2-2 所示），澄清网传取消机动车尾号限行的截图“并非来自官方”，而是其在业主群里聊起 ChatGPT 时用其拟写的。

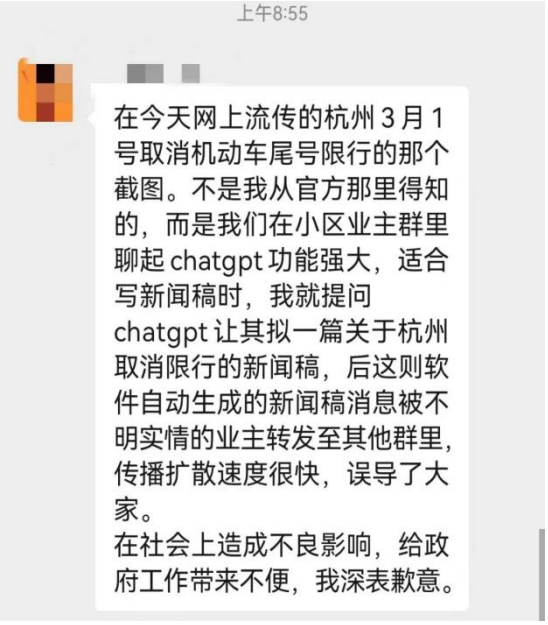


图 2-2 涉事业主道歉

2025 年 2 月 10 日，路透社报道，美国摩根律师事务所在一起针对沃尔玛公司销售缺陷悬浮滑板产品的诉讼中，因在法庭文件中引用了由人工智能生成的虚假司法判例，面临法律制裁（如图 2-3 所示）。据报道，原告律师在案件论证过程中共引用了 9 个虚构的司法案例，这些案例均由律所内部的 AI 系统生成，初看似乎为真实判例，后经核查确认这些所谓的案例均为 LLM 生成的幻觉内容[66]。



图 2-3 路透社新闻报道主页

在本研究中，我们对当前广受欢迎的两款大型语言模型（ChatGPT 和 DeepSeek）进行了测试，分别提出了“9.9 和 9.11 哪个大?”的问题。测试结果（如图 2-4 所示）表明，这两款大型模型均一本正经地给出了错误答案，并附带了振振有词的解释。尽管该问题看似简单，但模型的错误揭示出其在进行直观判断时可能出现的幻觉问题。这一现象暴露了大型语言模型即使在基础推理任务中也可能会产生偏差，意味着在处理相对简单的比较问题时，模型仍可能出现理解错误，进而对用户产生误导。



图 2-4 ChatGPT(左)和DeepSeek(右)测试

上述案例和测试表明，LLM 对社会带来的危害已呈现出系统性、多层次的威胁特征，其技术缺陷与社会应用场景的结合正在制造不可忽视的公共安全风险。

2.2 现有解决方案

根据 Ji 等研究者[1]的系统性综述，幻觉现象广泛存在于各类自然语言生成任务中，包括文本摘要[4]、问答系统[6]和对话生成[5]等关键场景。大型语言模型中的幻觉问题引起了相当大的关注，这引起了人们对大型语言模型的可靠性及其在实际应用中部署的担忧。值得注意的是，现有的研究中普遍将幻觉划分为两个类型：**忠实性幻觉**和**事实性幻觉**[17]。然而，当前领域中的研究**忽视了同一生成文本中可能同时存在两种幻觉形态交织**的复杂场景，导致鲜有能够同时针对这两类幻觉进行协同检测的**统一框架**。在此背景下，本研究提出的方法极具创新性和先进性，同时在全面性方面显著**超越了现有的工作**。

在人工智能和自然语言处理领域，**忠实性幻觉检测**已成为一项至关重要的研究任务。而针对于该任务的方法已经从传统的基于 N-gram 的指标（例如 BLEU[44]和 ROUGE[45]）发展到更加复杂的基于 LLM 的评估指标，例如允许用户自定义

评估标准的 G-Eval[46]。此外，研究者还提出了利用检索增强生成（RAG）[47]和基于知识图谱（KG）[48]的推理来减少生成输出中幻觉的技术。然而我们的方法与这些方法有很大不同，受 Ribeiro 学者的启发[32]，我们的方法显式地将整个语义结构编码到模型中，同时结合文本和图表示，从而在句子级别上实现更好的忠实性评估性能。

与此同时，**事实性幻觉**的检测任务仍然是一个开放的挑战，特别是对于只能作为黑盒访问的先进的闭源 LLM[2][3]。Lee 等学者[7]和 Manakul 等学者[8]探讨了开放域文本生成中的幻觉问题。然而，Lee 等学者的方法需要访问训练和推理的内部状态，由于闭源大语言模型的**黑箱特性**，用户很难直接介入或优化其内部机制来解决幻觉问题。显然，这对于只能作为黑盒访问的先进的闭源 LLM 显然有很大的局限性，但我们的系统通过整合用户提供的多款大语言模型的 API 密钥，促进了**跨不同模型**的事实可靠性和响应质量的横向比较。而与 Manakul 等学者的工作相比，我们的框架在幻觉检测方面和可解释性方面明显做的更出色。

Brewer 等研究者[9]发现，当人类说谎话时，他们常常会出现前后矛盾的情况。因此，一种常见的刑侦审讯技巧就是反复的采访，试图挑战采访者的一致性，以评估其可信度[10]。受此启发，Zhang，Du，Wang 等学者[11][12][13]提出了多采样方法，首先抽样多个初始答案，然后比较或考虑这些答案之间的差异，以得出一致的答案。虽然多样化的采样方法显著提高了大型语言模型输出可靠性的潜力，但它们仍然存在**过度自信**问题[14]（如图 2-5 所示）和**计算成本**等问题。由于 LLM 固有的偏见和信念，不同的抽样方法可能会反复产生**相同但错误**的答案，这限制了 LLM 对其他可能的正确答案进行对比。在评估一致性方面，语义熵[15]被提出用于衡量模型生成内容的不确定性，以检测随机器导致的**虚构**性幻觉。该方法通过采样多个生成答案，并基于语义一致性计算熵值，能够在无监督、无知识库的条件下检测幻觉。与传统的词级别或概率分布的不确定性估计不同，语义熵聚焦于语义层面的稳定性，适用于多种任务。然而，语义熵存在过度依赖模型自我不确定性的缺陷，即如果模型对错误答案语义熵值保持高一致性，语义熵可能无法有效检测幻觉。此外，它无法提供外部事实支撑，仅能判断答案是否自洽而无法验证其真实性，同时缺乏可解释性。为了解决上述问题，我们采用了语义熵计算与知识库检索相结合的互补增强方法，即使输出一致的错误答案，经过知识库检索后也会将其标识为幻觉并提供解释报告。



图 2-5 过度自信问题

2.3 本作品要解决的痛点问题

2.3.1 痛点问题一：语义表示不足导致检测精度低

在现有的研究中，纯文本序列评估源自传统 BLEU/ROUGE 理念，虽在衡量词汇和短语重合度方面表现可靠，却忽视了文本内部的概念关系和逻辑结构，缺乏对生成内容与上下文之间深层语义关系的建模能力，导致难以有效识别由隐含逻辑矛盾或概念结构偏差引发的忠实性幻觉。

此外，近年来基于 LLM 的评估指标在提升幻觉检测精度方面展现出显著优势。该类方法通过对生成文本进行多轮高质量推理和对比，捕捉表面序列匹配无法识别的细微语义偏差，显著增强了对忠实性幻觉的检测能力。然而，这种方法也带来了显著的效率瓶颈，频繁调用大型模型进行多次推理，不仅显著拉长响应延时，还大幅增加计算和调用成本，制约了系统在实时或大规模批量场景中的可用性。

综上所述，现有文本评估方法在语义表示能力上的不足，已成为限制幻觉检测精度提升的关键瓶颈。传统的评估机制由于缺乏对文本深层语义结构、概念关联及上下文逻辑的一体化建模，往往难以识别隐藏在语言流畅表面之下的忠实性偏差。近年来涌现的基于 LLM 的评估方法在一定程度上缓解了这一问题，凭借强大的推理与语义建模能力，有效提升了对细粒度语义偏差的感知与判断能力。然而，这类方法普遍依赖多轮推理与复杂比对，造成显著的计算成本与响应时延，难以满足实时检测或大规模评估的实际需求。因此，如何在提升语义表示质量的同时兼顾效率，成为当前幻觉检测研究亟需突破的核心难题。

2.3.2 痛点问题二：不一致性检测方法难以兼顾高确定性幻觉

现存最常见的事实性幻觉检测方法是基于**生成内容的不一致性**，但这类方法却面临着一个难以解决的挑战——**过度自信**。当模型对某个错误答案保持高度一致，无论随机采样多少次都生成相同或极其相似的错误内容时，不一致性检测将难以察觉其中的**幻觉**。为了研究过度自信问题，Fang 等研究人员[16]对具有代表性的多抽样方法进行了初步的实验,结果（如图 2-6 所示）验证了现有的多采样方法中均约有 40%以上的错误是由过度自信引起的。**如果无法有效解决 LLM 的高确定性幻觉问题，错误信息将以高度一致且自洽的方式传播，导致在医疗、法律等高风险领域产生严重后果，极大削弱其可信度和实际应用价值**。

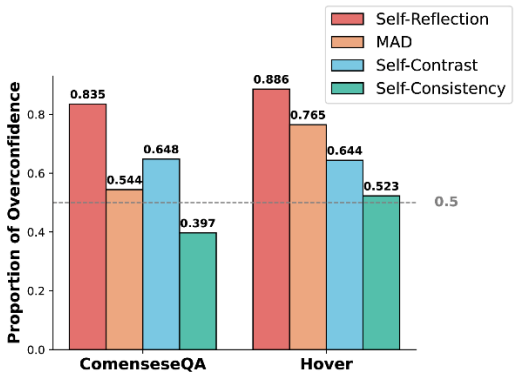


图 2-6 各方法错误答案中过度自信案例的占比

2.3.3 痛点问题三：幻觉检测结果缺乏可解释性

目前，大多数幻觉检测方法主要集中在识别生成的文本是否包含幻觉，而**未能提供详细的解释说明**。这些方法通常依赖于某些标准或规则，比如将输出与真实知识库进行比对，或者通过计算输出的熵值来判断其一致性，从而标记为幻觉。然而，这种方法往往只是给出一个**二元的判断结果，即仅给出检测结果是幻觉或非幻觉**，却没有对幻觉产生的原因提供**深入分析**。缺乏可解释性的幻觉检测结果，使得用户在面对检测结果时往往只能看到一个简单的标签，而**无法了解导致该判断的具体原因**，这不仅降低了检测工具的透明度，还影响了用户对其判断准确性的信任，同时也限制了研究者对模型错误进行针对性修正和优化的可能性。

2.4 解决问题的思路

2.4.1 作品功能分析

1. 多模型接入与使用：用户可在平台上调用不同的大语言模型，自由选择并进行文本生成或幻觉检测。

2. 自动全幻觉检测：系统通过将大语言模型生成的内容输入到互补增强幻觉检测模块，判断生成内容是否为幻觉。

3. 幻觉句子定位：系统可以检测大语言模型生成内容中的幻觉，并精准定位到产生幻觉的句子，同时可视化标记该句子，将该句子的字体颜色改为为红色。

4. 幻觉成因分析：系统返回的检测结果中含有对幻觉成因分析的报告，解释每个被标记的句子产生幻觉的原因。

2.4.2 检测指标

Faithful/Non-Faithful 类别预测的评估指标：

1. 平衡准确率 (Balanced Accuracy，BACC) ：平衡准确率是二分类任务中，正类 (Faithful) 和负类 (Non-Faithful) 的预测准确率的算术平均值。

2. Micro F1 分数：Micro F1 分数是基于所有样本的全局统计量，计算总体精确率（Precision）和召回率（Recall）的调和平均数。

Factual/Non-Factual 类别预测的评估指标：

1. AUROC (Area Under the Receiver Operating Characteristic Curve) ：AUROC 是接收者操作特征曲线（ROC 曲线）下的面积，用于评估二元分类器在不同阈值下的综合性能，值越高表示模型性能越好。

2. AURAC (Area Under the Rejection Accuracy Curve) ：AURAC 是“拒绝准确率曲线”下的面积，反映模型通过拒绝高不确定性答案后的准确率变化。AURAC 越高，表明不确定性指标越能指导过滤低质量回答。

人工评估指标：

1. 合理性：人类评估者直接指出幻觉分析中哪些是有问题的，检查分析是否包含幻觉或者不合逻辑的推理。

2. 全面性：人类评估者仔细审查输入、输出和幻觉分析，判断是否存在该系统没有发现的其他幻觉。基于分析，人类评估者会在 1 到 4 的评分范围内给出分

数（重点关注被遗忘的潜在幻觉）。

3. 有效性：人类评估者评估幻觉分析是否有助于改善模型的输出质量。按 1 至 5 分评分，判断其对改进输出的实际帮助程度。

4. 总体评价：人类评估者综合合理性、全面性和有效性，按 1 至 5 分给出整体评分。

2.4.3 数据集

1. 数据集：对于忠实性幻觉检测，我们使用 QAGS-C[59]、QAGS-X[59]和 FRANK[60]数据集进行实验评估。对于事实性幻觉检测，我们的评估涵盖了知识问答 （TriviaQA[61]），常识问答（SQuAD[62]），以及源自 Google 搜索真实查询的开放域自然问答（NQ-Open[63]）。

2. 数据集来源：

   QAGS：https://github.com/W4ngatang/qags/tree/master/data

   FRANK：https://github.com/artidoro/frank/tree/main/data

   TriviaQA：https://nlp.cs.washington.edu/triviaqa/

   SQuAD：https://rajpurkar.github.io/SQuAD-explorer/

   NQ-Open：https://huggingface.co/datasets/google-research-datasets/nq_open

3. 数据格式

   QAGS-C：{

   ```
   "article": "...",
   "summary_sentences": [
      {
         "sentence": "...",
         "responses": [
            {"worker_id": 0, "response": "yes/no"},
            ...
         ]},
      ...
   ]}
   ```

QAGS-X：{

"article": "...",

"summary_sentences": [

{

"sentence": "...",

"responses": [

{"worker_id": ..., "response": "..."},

{"worker_id": ..., "response": "..."},

{"worker_id": ..., "response": "..."}

]}]}

FRANK：{

"hash": "…",

"model_name": "…",

"article": "...",

"summary": "...",

"reference": "…",

"summary_sentences": [

"..."

],

"summary_sentences_annotations": [

{

"annotator_0": [

"…"

],

"annotator_1": [

"…"

],

"annotator_2": [

"…",

"…"

```
                ]}],
        "split": "test"     //数据划分标识(验证集和测试集)
    }
```

TriviaQA：{

```
  "QuestionID": "...",
  "Question": "...",
  "Answer": ["..."],
  "Supporting_Documents": [
    "...",
    "..."
  ]}
```

SQuAD：{

```
    "data": [
        {
            "title": "...",
            "paragraphs": [
                {
                    "context": "...",
                    "qas": [
                        {
                            "answers": [
                                {
                                    "answer_start": 0,
                                    "text": "..."
                                },{
                                    "answer_start": 0,
                                    "text": "..."
                                },{
                                    "answer_start": 0,
```

"text": "..."

}],

"question": "...",

"id": "..."

}]}]}],

"version": "..."

}

NQ-Open:{

question: "..."

answer: ["..."]

}

4. 数据特点

QAGS：QAGS 是一个用于评估摘要事实一致性的数据集，包含两个子集：QAGS-C 和 QAGS-X，覆盖不同的摘要风格（XSum 的极端摘要和 CNN/DailyMail 的传统摘要）。数据集均经过人工标注，由三名标注者评估每个句子与原文的一致性，采用多数投票决定最终标签。同时，该数据集以句子级进行人工标注，是目前相关学术文献中最流行的基准测试数据集之一。

FRANK：FRAMK 是 Pagnoni[50]等学者提出的针对句子级摘要的事实性进行评估数据集。在数据集的构建过程中，标注者对模型生成的摘要逐句进行标注，判断每个句子是否包含事实性错误，并在错误发生时基于语言学理论定义七类错误，且允许标注者为一个句子标记多个错误类型。

TriviaQA：TriviaQA 的特点是其问题相对复杂，具有较高的语法和词汇变异性，以及需要更多的跨句推理来找到答案。数据集适用于训练新的阅读理解模型，旨在解决机器阅读理解中的复杂问题，如组合性问题、多句推理和词汇及语法变异。

SQuAD：SQuAD 数据集以其高质量和多样性著称，涵盖了广泛的领域和主题，包括历史、科学、文化等。每个问题都与特定的文章段落紧密相关，且答案直接从段落中提取，确保了数据的准确性和可解释性。此外，数据集还提供了答案的开始和结束位置，便于模型进行精确的答案定位和评估。

NQ-Open：NQ-Open 数据集适用于开放域问答任务的研究与开发，尤其

适合用于训练和评估问答模型。用户可通过加载数据集中的问题与答案字段，构建和优化问答系统。数据集的简洁结构和大规模样本使其成为研究和实践的理想选择，尤其在需要处理开放域问题的场景中。

5. 数据规模：

QAGS：QAGS-C 基于 CNN/DailyMail 数据集构建，包含 235 个摘要，每个摘要的句子由人工标注事实一致性。统计分析该数据集平均摘要长度为 49 个单词，平均上下文长度为 383 个单词，48.1%的摘要被标记为一致；QAGS-X 基于 XSum 数据集构建，包含 239 个摘要，每个摘要的句子由人工标注事实一致性。统计分析得该数据集平均摘要长度为 18 个单词，显著短于其他数据集。同时，平均上下文长度为 318 个单词，48.5%的摘要被标记为一致。

FRANK：FRANK 数据集包含 4942 个句子级标注，覆盖 2,250 篇由不同模型生成的新闻摘要（CNN/DM 和 XSum 数据集），每句由 3 位标注者独立标记事实性错误，共定义 7 类错误类型。数据严格划分为验证集和测试集，是当前规模较大、标注粒度较细的摘要事实性检测基准之一，尤其适合训练句子级二分类或细粒度错误分析模型。

TriviaQA：该数据集包含超过 650K 个问题-答案-证据三元组，结合 95K 个由爱好者撰写的问题-答案对和平均每个问题 6 个独立的证据文件组成，为回答问题提供高质量的远程监督。

SQuAD：SQuAD 1.1 包含超过 10 万个问题，所有答案均直接来源于对应的维基百科段落，原文来自于 536 篇维基百科文章。SQuAD2.0 组合了 SQuAD1.1 中的 10 万个问题，并增加了超过 5 万个无法回答的问题。

NQ-Open：该数据集包含 87925 条训练样本和 3610 条验证样本，结构简洁，包含问题与答案两个主要字段。

6. 数据样例

QAGS-C： {"article": "David beckham's 40th birthday celebrations next weekend were never going to be a small affair...", "summary_sentences": [{"sentence": "David beckham's 40th birthday is on saturday, 2 may and it is thought he will be staying at the five-star luxury amanjena resort, just outside marrakech.", "responses": [{"worker_id": 156, "response": "yes"}, {"worker_id": 66, "response": "no"}, {"worker_id": 173, "response": "no"}]}, {"sentence": "Amanjena resort amanjena is the first aman resort on the african continent and is

located just outside the ancient city of marrakech.", "responses": [{"worker_id": 156, "response": "yes"}, {"worker_id": 66, "response": "yes"}, {"worker_id": 173, "response": "yes"}]}, {"sentence": "The star is expected to fly out to morocco for a five-star bash with his celebrity friends and family.", "responses": [{"worker_id": 156, "response": "yes"}, {"worker_id": 66, "response": "yes"}, {"worker_id": 173, "response": "yes"}]}]}

QAGS-X：{"article": "India finished the opening day...", "summary_sentences": [{"sentence": "India's batsmen dominated the first day of the third and final test against south africa with an innings-and-96-run win.", "responses": [{"worker_id": 1, "response": "no"}, {"worker_id": 13, "response": "no"}, {"worker_id": 4, "response": "no"}]}]}

FRANK：{

"hash": "35933239",

"model_name": "BERTS2S",

"article": "Police in Arkansas wish to unlock an iPhone and iPod belonging to two teenagers accused of killing a couple, according to the Associated Press (AP)…",

"summary": "the fbi has said it will help the san bernardino killer to access iphones used by the san bernardino victims.",

"reference": "the fbi has offered to unlock another iphone for police after revealing it could access the handset used by san bernardino killer syed farook.",

"summary_sentences": [

"the fbi has said it will help the san bernardino killer to access iphones used by the san bernardino victims."

],

"summary_sentences_annotations": [

{"annotator_0": [

"RelE"

],

"annotator_1": [

"EntE"

],

"annotator_2": [

"EntE",

"CircE"

]}],

"split": "test"

}

TriviaQA：{

"QuestionID": "triviaqa-0001",

"Question": "Who directed the movie Inception?",

"Answer": ["Christopher Nolan", "Nolan"],

"Supporting_Documents": [

"Inception is a 2010 science fiction film directed by Christopher Nolan...",

"The film, directed by Nolan, received widespread acclaim..."

]

}

SQuAD：{

'title': 'Beyoncé',

'paragraphs': [

{'qas': [{'question': 'When did Beyonce start becoming popular?',

'id': '56be85543aeaaa14008c9063',

'answers': [{'text': 'in the late 1990s', 'answer_start': 269}],

'is_impossible': False}]],

'context':'Beyoncé Giselle Knowles-Carter …'}

}

NQ-Open：{

"question": "names of the metropolitan municipalities in south africa",

"answer": [

"Mangaung Metropolitan Municipality",

"Nelson Mandela Bay Metropolitan Municipality",

"eThekwini Metropolitan Municipality",

"City of Tshwane Metropolitan Municipality",

"City of Johannesburg Metropolitan Municipality",

"Buffalo City Metropolitan Municipality",

"City of Ekurhuleni Metropolitan Municipality"

]}

第3章 技术方案

项目的核心模块为三部分：1.事实性幻觉检测模块；2.忠实性幻觉检测模块；3.幻觉解释模块。此外还有预处理和用户交互模块。项目一览图如图 3-1 所示：

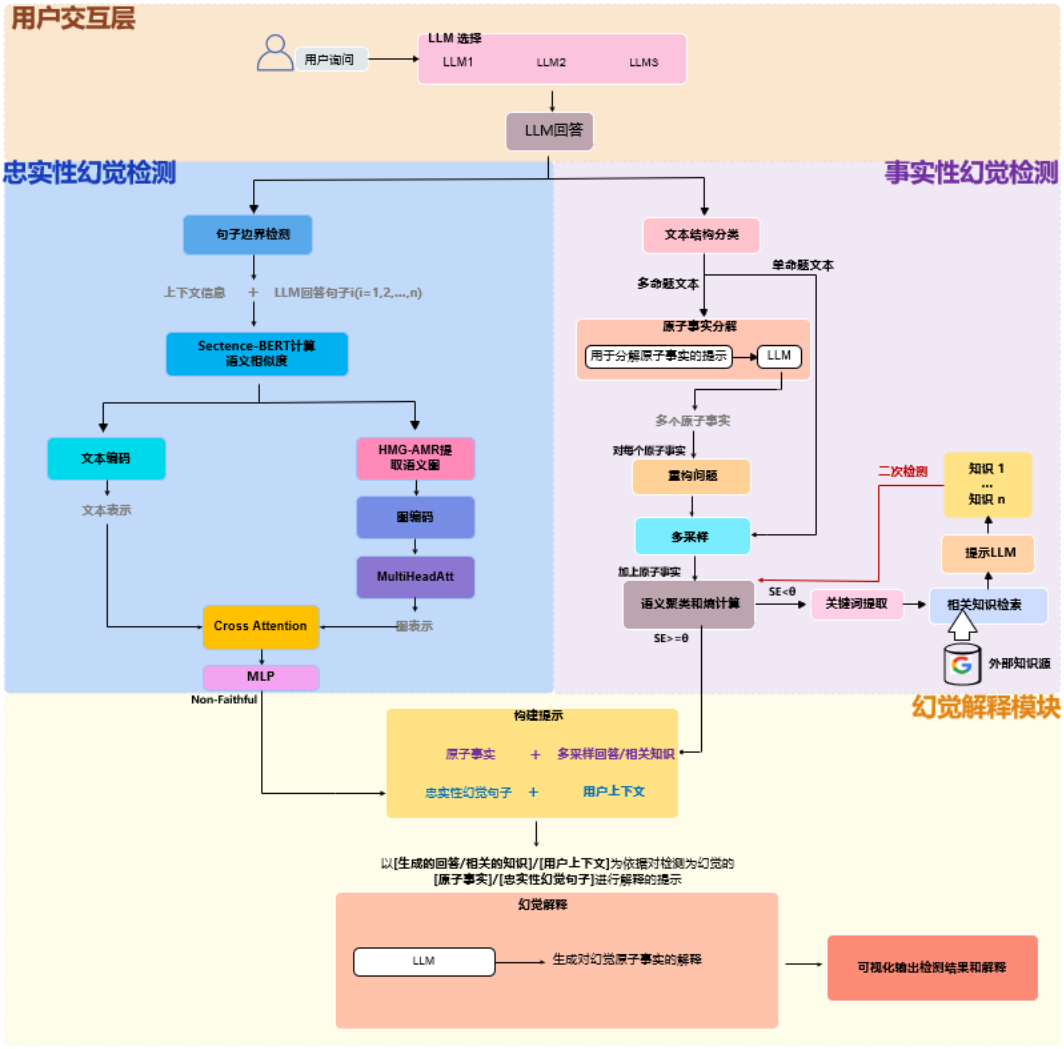


图 3-1 项目一览图

3.1 忠实性幻觉检测模块

忠实性幻觉检测模块通过句子级别的分析，精确检测开放式生成任务中 LLM 输出的答案与用户上下文信息之间的差异，识别其中可能存在的忠实性幻觉。

这项工作旨在评估 LLM 在给定上下文情境下的忠实性表现。具体来说，我们关注模型生成的文本输出是否严格基于提供的上下文信息，而不引入与输入信息相矛盾或无根据的内容。所有关于**事实知识**的开放领域问题，我们使用与之并行的事实性幻觉检测模块 3.2 节进行讨论。

既往的许多方法通过文本或实体间的依赖关系来识别文档间的信息差异，但往往忽略了整体语义结构的考虑。为了弥补这一缺陷，我们通过将用户给定的上下文信息和 LLM 生成的答案转化为更适合于事实性评估的结构化意义表示 (MR) ，来实现句子级忠实性幻觉的检测。具体来说，受 Banarescu[31]和 Ribeiro[32]等学者的启发，我们使用 AMR（抽象意义表示）（如图 3-2 所示）作为结构化语义图来建模核心语义概念（节点）及其语义关系（边），消除了句法结构的影响。接着，通过图形编码器结合结构感知适配器，根据图的连通性捕捉这些概念之间的交互，以及使用基于适配器的文本编码器进一步增强了文本表示的语义深度，确保了对 LLM 输出答案的每个句子的详细比对，从而有效地识别出幻觉内容。

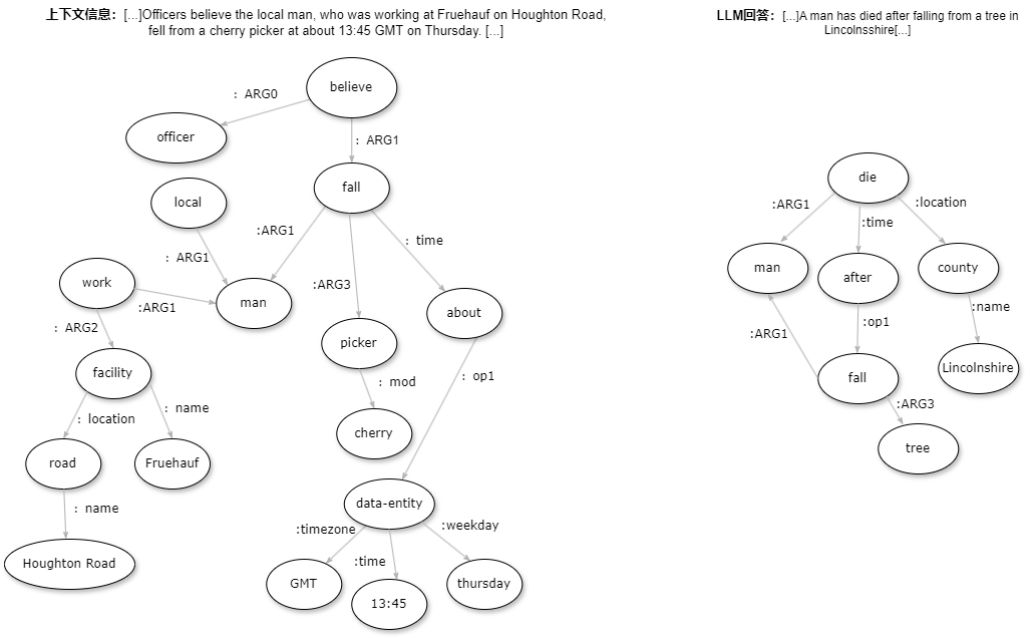


图 3-2 AMR语义图示例

忠实型幻觉检测模块一览图如图 3-3 所示。该图展示了忠实性幻觉检测的

整个框架结构，它由 3.1.2 节介绍的文本编码器和图编码器组成。文本编码器（记为 E_t）使用预训练编码器 ELECTRA[41]标记为 E，并通过适配器模块增强，接收 LLM 回答 R 和上下文信息 D 作为输入，输出上下文文本表示。同样地，图编码器（记为 E_g）同样使用预训练编码器 E，通过结构感知适配器增强。E_g 接收 LLM 回答及其句子对应的多个上下文信息语义图，输出基于图结构的上下文表示，用于最终的图表示。在训练的过程中，仅训练适配器的权重，而 E 的权重保持不变。最后，将图和文本表示通过双向交叉注意力机制融合后，预测 LLM 是否忠于上下文信息。

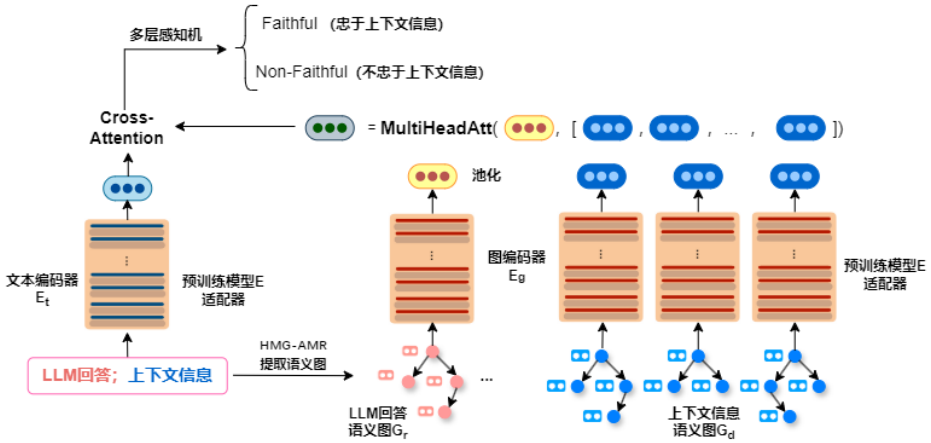


图 3-3 忠实性幻觉检测模块一览图

基于上述整体框架与前提，接下来将进一步详细介绍忠实性幻觉检测模块的各个组成部分。

3.1.1 语义图转化

对于语义图的提取工作，我们使用当前最先进的 AMR 解析方法来提取 AMR 图 $\mathcal{G}_a = (\mathcal{V}_a, \mathcal{E}_a, \mathcal{R}_a)$，其节点集为 $\mathcal{V}_a$，带标签的边 $(u, r, v) \in \mathcal{E}_a$（其中 $u, v \in \mathcal{V}_a, r \in \mathcal{R}_a$ 为关系类型），每个 $\mathcal{G}_a$ 旨在显式表示句子中的核心概念。具体地，对于给定的上下文信息 D 和句子级 LLM 生成答案 R，我们的目标是检查 R 相对于 D 是否为事实。对于每个句子 d∈D，我们提取其对应的 AMR 语义图 $\mathcal{G}_d$，同样地，对于生成的答案 R，我们提取其 AMR 语义图 $\mathcal{G}_r$。

针对 AMR 解析，本项目使用 HMG-AMR 架构[35]，框架如图 3-4 所示。

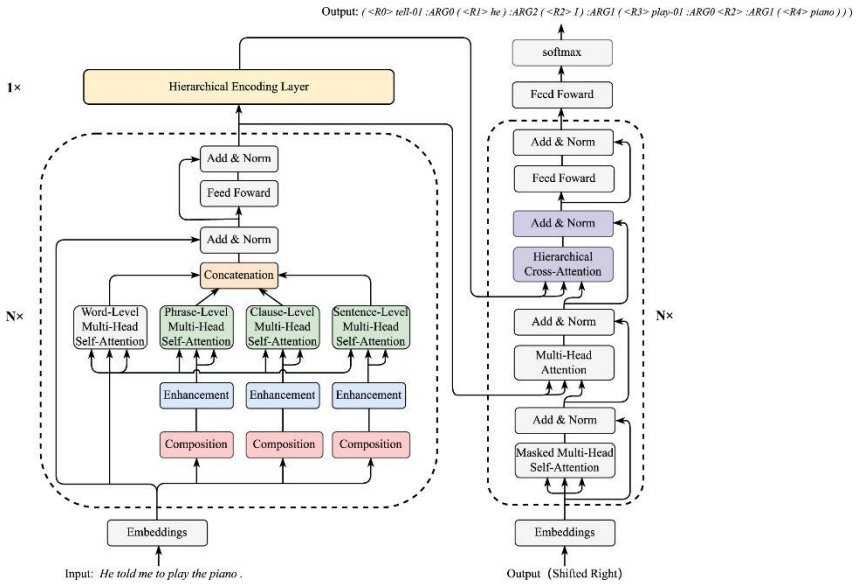


图 3-4 HMG-AMR架构一览图

首先，将输入的自然语言文本通过现有的解析器，解析组合为包含句子级、子句级、短语级和单词级文本跨度的结构模式，表示为（如图 3-5 所示）的层次多粒度 (HMG) 结构。其中每个节点是一个多粒度文本跨度，每个有向边是它们之间的一个关系。

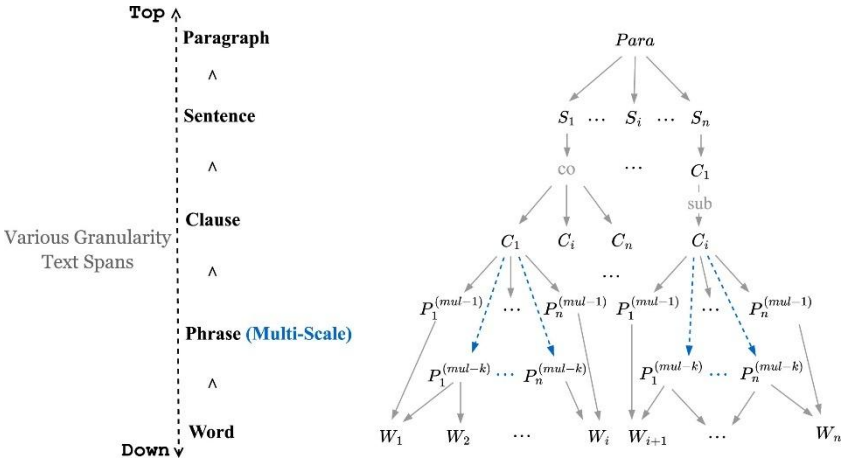


图 3-5 层次多粒度结构

接下来，使用 HMG-AMR 架构进行 AMR 解析。具体地，我们结合图 3-6 所示的编码器数据流进行解析。在图中，每个层次的文本单元（短语/子句/句子）在组合层 (Composition Layer) 通过平均池化生成初始表示 $h^{(s)}$，$h^{(c)}$，$h^{(p)}$分别表示输入文本的初始句子级、初始子句级和初始短语级表示。接着，在组合层之后引入增强层 (Enhancement Layer) ，使用有序神经元 LSTM (ON-LSTM) 为增强函数来模拟各种粒度序列的潜在结构，生成 $h^{(s)'}$，$h^{(c)'}$，$h^{(p)'}$分别表示增强后的句子级、子句级和短语级表示。接下来，使用多粒度自注意力机制 (Multi-Granularity

Self-Attention) 对每个粒度都设计一个专门的自注意力机制头，生成 $O_{(s)}$,$O_{(c)}$,$O_{(p)}$ 包含单词和短语之间、单词和子句之间以及单词和句子之间的信息。接着，将每个粒度的自注意力输出与原始词级注意力 $O_{(w)}$组合在拼接层 (Concatenation Layer) 中，生成 $\hat{H}$ 表示为多粒度跨度编码模块的输出。最后，输出值 $\hat{H}$ 经过编码器后续层后，得到编码器最终表示$\mathbf{H}^*$。

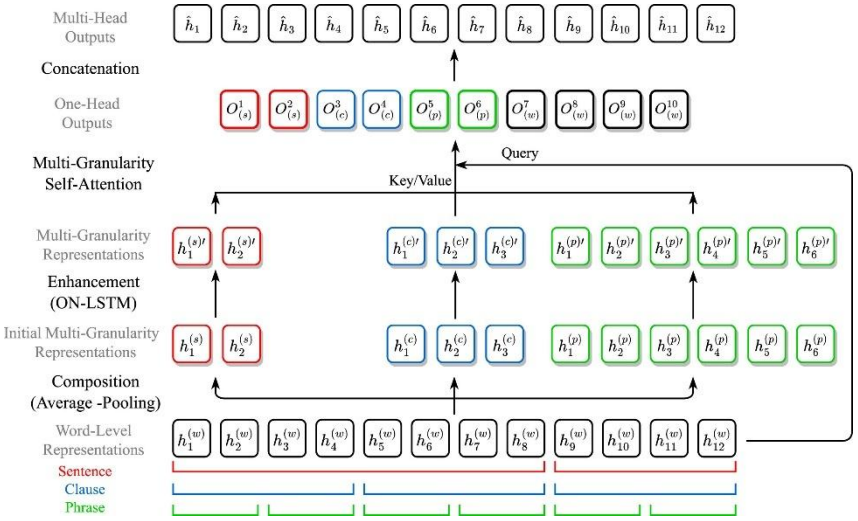


图 3-6 编码器数据流

接着，在如图 3-7 所示的分层编码层 (Hierarchical encoding layer) 中，使用随机选择编码器的某一层输出，通过平均池化生成句子级全局表示 H_{hie}。

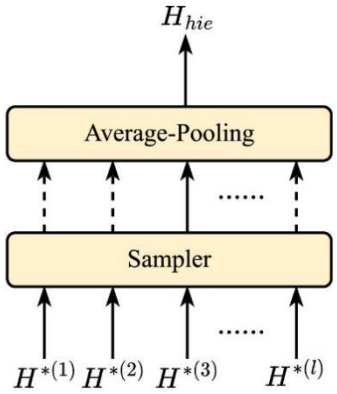


图 3-7 分层编码层

在解码器中，该架构与传统的 Transformer 的不同之处在于分层交叉注意机制 (Hierarchical cross-attention) 。具体来说，在传统的 Transformer 中，每一层解码器首先对已生成的 Tokens 进行自注意力计算，随后在解码过程中关注编码器最终层的词级输出。而该解码器引入分层交叉注意机制如图 3-8 所示。在自注意力机制之后，解码器的嵌入首先与词级输出进行交互，随后与句子级输出交互，

确保生成 AMR 时兼顾局部词义和全局句义。

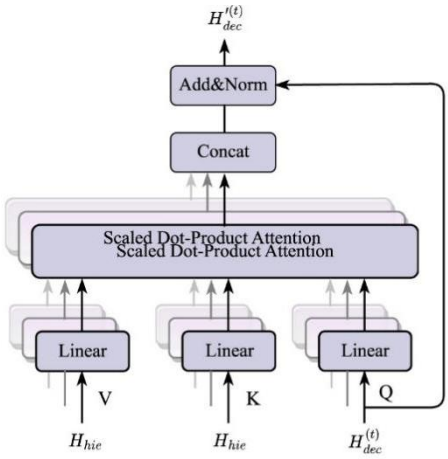


图 3-8 分层多头交叉注意力机制

最后，对 HMG 框架进行微调，生成线性化的 AMR 图。（为避免歧义，此处解释一下为什么是线性化的 AMR 图——Sataer 等学者[35]是通过深度优先搜索的遍历顺序将 AMR 图线性化为序列，因此在这项工作中 AMR 解析可以表述为序列到序列的转换问题）

3.1.2 双模态编码

对于**文本编码表示**，我们使用预训练编码器 ELECTRA 编码，并通过适配器模块增强。具体来说，在编码器每一层的前馈子层前后均使用适配器模块，集成方式如图 3-9 所示（为清晰起见省略了层归一化与残差连接）。

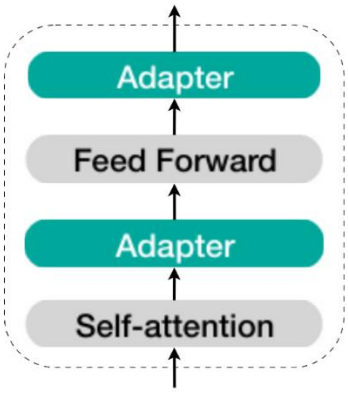


图 3-9 文本适配器的集成方式

我们对 Houlsby 等学者[38]的适配器架构进行了修改，修改后的架构如图 3-10 所示。对于每一层 l 的每个词元 (Token) i，给定词元表示h_i^l，其适配器表示计算如下：

$$\hat{\boldsymbol{z}}_i^l = W_o^l\left(\sigma\left(W_p^l \mathrm{LN}(h_i^l)\right)\right) + h_i^l, \tag{1}$$

其中，σ 是激活函数，LN(·)表示层归一化，$W_o^l \in \mathbb{R}^{d\times m}$和$W_p^l \in \mathbb{R}^{m\times d}$是适配器参数。[CLS] 词元的表示作为最终的文本表示，记为 t，作为整个句子的语义摘要。

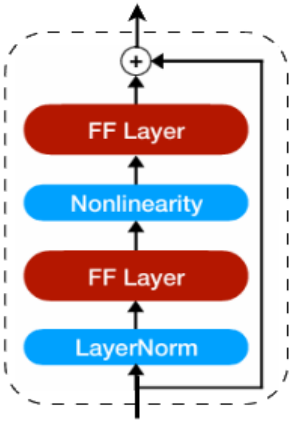


图 3-10 文本适配器结构

对于**图表示编码**，我们发现该预训练模型输入是子词标记 (Subword Token) ，而 AMR 节点是短语或者完整词。故此我们需要将 AMR 图转化为适合预训练模型处理的图结构。具体地，我们将每个$\mathcal{G}_a$转化为二分图$\mathcal{G}_b = (\mathcal{V}_b, \mathcal{E}_b)$，将每条带标签的边$(u, r, v) \in \mathcal{E}_a$替换为两条无标签边$\{(u, r), (r, v)\} \in \mathcal{E}_b$，此过程将图转换为无标签版本，图 3-11 展示了(a)AMR 子图及其(b)无标签表示。接着，我们将每个$\mathcal{G}_b$转换为新的标记图$\mathcal{G} = (\mathcal{V}, \mathcal{E})$，其中节点$v_b \in \mathcal{V}_b$的每个 Token 成为一个节点$v \in \mathcal{V}$。我们将每条边$(u_b, v_b) \in \mathcal{E}_b$转换为一组边，连接$u_b$的每个 Token 与$v_b$的每个 Token。图 3-11(c)展示了标记图示例。

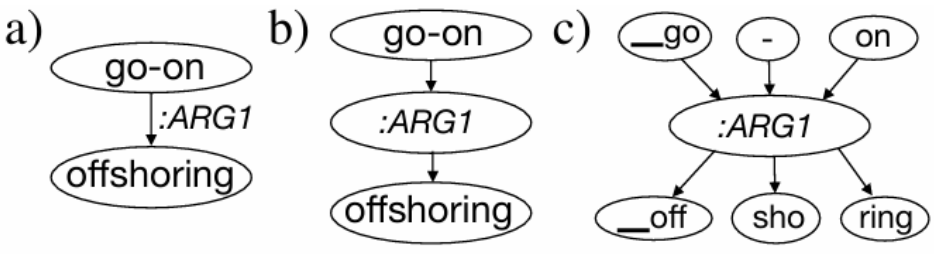


图 3-11 (a)AMR图结构，(b)其无标签版本，(c)标记图

接着，为了将预训练编码器适配于结构化输入，我们采用了一种结构适配器，放置在每一层的前馈子层之前，而普通适配器放置在前馈子层之后，该结构如图 3-12 所示。

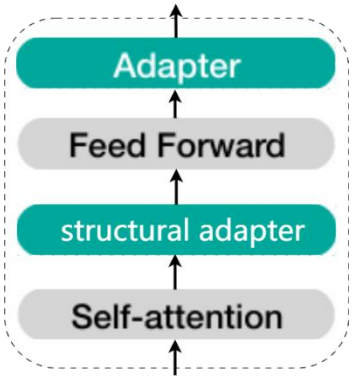


图 3-12 结构适配器的集成方式

受 Ribeiro 等学者启发[42]，我们设计的结构适配器如图 3-13 所示。具体地，对于每个节点$v \in \mathcal{V}$，给定隐藏表示h_v^l，编码层 l 计算如下：

$$g_v^l = \text{GraphConv}_l(\text{LN}(h_v^l), \{\text{LN}(h_u^l): u \in \mathcal{N}(v)\})$$
$$z_v^l = W_e^l \sigma(g_v^l) + h_v^l, \quad (2)$$

其中$\mathcal{N}(v)$是节点 v 在 $\mathcal{G}$ 中邻域，$\mathrm{W}_e^l \in \mathbb{R}^{d \times m}$是适配器参数。$\text{GraphConv}_l(\cdot)$是基于节点邻域的图卷积操作，用于计算节点 v 的表示。卷积操作采用关系图卷积网络[37]作为图卷积，该网络考虑了输入和输出关系的差异。

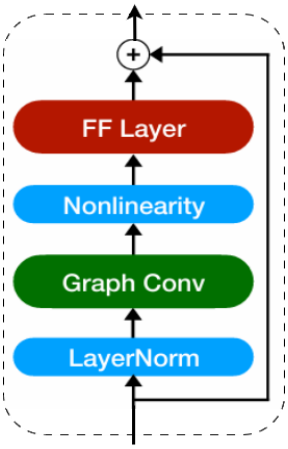


图 3-13 结构适配器架构

接下来，我们对最后一层的所有节点表示通过池化操作，计算每个图的最终表示，记为$z^{\mathrm{G}} = \{\mathrm{z}_v^{(L)} \mid v \in \mathcal{V}\}$，其中$\mathrm{z}_v^{(L)}$是节点$v$的最终表示，$z^{\mathrm{G}}$是图的全局表示。

最后，我们使用多头自注意力机制[40]估计每个句子图对文档语义表示的贡献程度。这一机制能够基于 LLM 回答图编码上下文信息表示。具体来说，每个注意力头计算：

$$\alpha_i = \text{Attn}(z_r^{\mathrm{G}}, z_i^{\mathrm{G}}),$$

$$g = \sum_{i=1}^{k} \alpha_i W_r z_i^{\mathrm{G}}, \tag{3}$$

其中 z_r^{G} 是 LLM 回答图 $\mathcal{G}_r$的最终表示，α_i 是 LLM 回答图 z_r^{G}与上下文信息各句子图z_i^{G}的关联权重，k 是上下文中考虑的句子图数量，$\mathrm{W}_r \in \mathbb{R}^{d\times d}$是参数。

3.1.3 句子级忠实性分类

在完成文本编码器和图编码器的表示生成后，我们获得了两个不同模态的语义表示：文本模态的表示 t（从 ELECTRA 编码器中 [CLS] 位置获得）以及图模态的表示 g（从结构适配器图池化后获得），不仅能捕捉到文本模态下的表面信息，而且能验证图模态下的结构化语义。故此，双模态融合能够显著弥补纯文本方法对隐含逻辑关系建模的不足。具体地，最终表示使用交叉注意力机制 (Cross Attention Mechanism) 对这两个模态进行深度融合，以提升跨模态信息交互和忠实性判断的能力，即：

$$\alpha_{t\to g} = \mathrm{Softmax}\left(\frac{tW_Q(gW_K)^{\top}}{\sqrt{d}}\right), \tilde{g} = \alpha_{t\to g}\cdot(gW_V)$$

$$\alpha_{g\to t} = \mathrm{Softmax}\left(\frac{gW_Q'(tW_K')^{\top}}{\sqrt{d}}\right), \tilde{t} = \alpha_{g\to t}\cdot(tW_V') \tag{4}$$

$$q = \mathrm{LayerNorm}([t;\tilde{g}] + [\tilde{t};g])$$

其中，$W_Q, W_K \in \mathbb{R}^{d\times d}$为可学习参数，$d$ 为向量维度，$W_V \in \mathbb{R}^{d\times d}$为值投影矩阵。

接下来，将综合文本模态和图模态的信息表示 q 输入到分类层，输出标签 $y = \{\mathrm{Faithful}, \mathrm{Non-Faithful}\}$的概率分布。

最后，损失函数使用标准的交叉熵损失（CrossEntropy Loss）：

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(p_i) + (1-y_i)\log(1-p_i)], \tag{5}$$

其中，N 表示批次中的样本数量，$y_i \in \{0,1\}$表示真实标签（1 表示忠实，0 表示不忠实），p_i 表示模型预测句子级 LLM 回答 i 为忠实的概率。

3.2 事实性幻觉检测

事实性幻觉是指模型生成的内容与可验证的现实世界事实不一致。鉴于事实

性幻觉的可验证性特征，本研究采用语义熵结合外部知识库的方法进行幻觉检测。

语义熵结合外部知识库的检测方法（内外部知识结合）具有显著优势。语义熵方法能够提供精确且高效的可解释性检测，通过衡量文本中的不确定性来识别生成内容的不一致性。然而，对于低熵幻觉问题，即模型输出多个相同的幻觉内容时，语义熵方法可能难以奏效。而外部知识库的引入则有效弥补了这一不足，通过检索外部知识库来验证生成内容的真实性。此外，语义熵的应用还改善了外部知识库检索的效率问题，缓解了其检索速度慢、数据体量大的弊端。

事实性幻觉检测模块的整体流程如图 3-14 所示。

在模型生成回答的过程中，首先通过流程导向模块对输出内容进行分类，将其划分为单命题回答和多命题回答。这种区分是必要的，其详细理由在 3.2.1 节中进行了阐述。

对于可能存在幻觉的单/多命题回答，进一步计算其语义熵。若计算得到的熵值较高，则表明该回答存在事实性幻觉[18]。此时，幻觉检测流程结束，相关结果直接送入解释模块进行后续处理，具体过程在 3.3 节中有详细说明。

对于低熵情况，存在输出多个相同幻觉内容的可能性[17][18]。针对此类情况，进一步采用知识库检测方法。通过检索外部知识库，获取与回答相关的内容，并将检索得到的事实性论证返回至语义熵模块，进行下一次验证。这一流程旨在综合语义熵和外部知识库的优势，提高幻觉检测的准确性和可靠性。

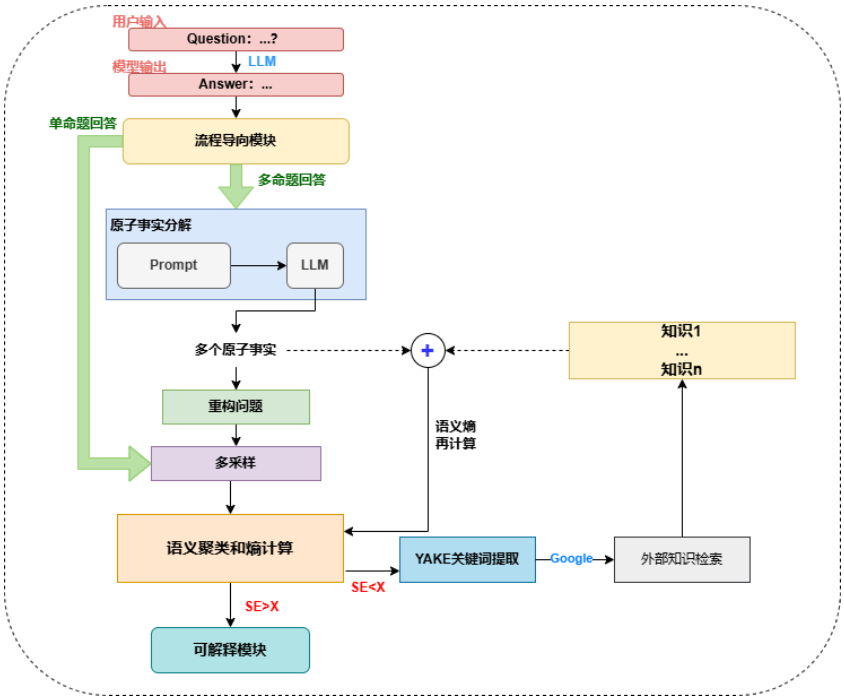


图 3-14 事实性幻觉检测流程

3.2.1 流程导向模块

在语义熵的计算中，单命题和多命题回答存在显著差异，主要体现在以下几个方面：

信息量与复杂性：单命题回答：通常只包含一个核心语义单元，信息量相对较少，结构较为简单。其语义熵主要反映该单一命题的语义不确定性。多命题回答：包含多个语义单元，信息量更大，结构更复杂。其语义熵不仅反映每个命题的不确定性，还涉及命题之间的语义关联。

语义关联性：单命题回答：语义关联性较为单一，主要围绕一个主题展开，语义熵的计算相对直接。多命题回答：命题之间可能存在多种语义关系（如并列、因果、递进等），这些关系增加了语义熵的计算复杂性。

幻觉检测的敏感性：单命题回答：由于信息量较少，语义熵可能较低，但在某些情况下，单一命题的错误可能导致较高的语义熵，从而更容易被检测。多命题回答：由于包含多个命题，即使部分命题存在幻觉，整体语义熵可能仍处于较低水平，这增加了幻觉检测的难度。

将回答分为单命题和多命题回答，能够更好地利用语义熵的特性，提高幻觉检测的准确性和效率，同时增强模型的可解释性。

流程导向模块的功能是通过句子边界检查和依存句法分析，分别统计文本中的句子数量及分割成独立句子单元中的命题 (factoid) 数量，借此评估 LLM 输出的文本结构，之后依据文本结构的差异，采用相应的检测方法。考虑到不同输出的长度特性，在本文档中，我们暂且将文本结构划分为两大类别，以更好地适应我们的工作需求：**单命题文本**和**多命题文本**。

在 LLM 的**幻觉检测任务**中，对**文本结构**的**判断**至关重要。**一方面**，语义熵最适用于表达**单一命题**的句子，可以根据同一提示的若干次的回答内容计算语义熵，从而判断语义一致性。然而，将语义等价的概念应用于表达多个命题的较长段落则更为复杂，这些命题可能只部分一致。**另一方面**，长文本往往包含更多的信息，如果针对长文本重新生成的若干次回答计算语义熵，重新采样的句子可能会针对不同方面。举例来说，LLM 生成人物传记时，重新采样的句子往往会针对人物的不同方面：一次描述家庭，另一次描述职业。这就类似于语义熵最初要解决的问题，即模型对事实顺序的不确定性，而不是对事实本身的不确定性。为了解决上述问题，我们需要对不同结构的文本进行“分流”，通过对 LLM 输出

的文本结构判断，针对不同结构的文本使用不同的语义熵值计算方法。

鉴于幻觉检测任务对时效性的特定要求，以及大语言模型生成文本的开放性特征，我们选用 spaCy 基于 transformer 架构的预训练英语模型 (en_core_web_trf) 作为核心模块。为优化大规模 LLM 生成文本的处理效率，我们在流水线中禁用了非必要组件，同时保留关键语言标注功能，有效提升处理效率。经实验验证后证明了我们的流程导向模块在 LLM 幻觉检测任务中的**高效性能**。

流程导向模块主要包括句子边界检查、依存句法分析、文本结构分类。

句子边界检查：为精确分割 LLM 生成的开放领域文本，我们依托 spaCy 的混合句子分割器，实现了 LLM 生成文本的句子边界检测，进而获取生成文本的句子数量并将文本分割成独立的句子单元。例如，当我们在幻觉检测平台上选定一个 LLM 后，输入问题 Q：“Where is the Eiffel Tower?”，假设此时的 LLM 生成答案 A 为：“The Eiffel Tower is located in Paris.”。在 LLM 输出文本上调用 NLP 模型时，**定制化** spaCy 完整处理流水线如图 3-15 所示。

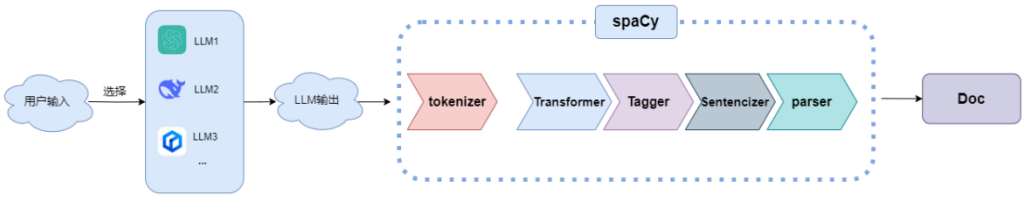


图 3-15 定制化Spacy一览图

首先，通过隐式的分词器 (Tokenizer) 组件将原始文本 A 拆解为词符 (Token)，生成 Token 序列 S["The", "Eiffel", "Tower", "is", "located", "in", "Paris", "."]。

接下来，由集成在 en_core_web_trf 模型中的 Transformer 组件对 S 中的每个 Token 生成若干维向量，这些向量捕获了词符的语义和上下文信息，由此生成上下文相关的词符嵌入，能有效捕获生成文本的句法规律性，可缓解 LLM 输出中偶尔出现的语义不连贯导致的解析错误，为后续任务提供语义基础。

接着，由集成的 Tagger 组件为每个 Token 分配一个词性标签，用于描述词符的语法角色。在本例中，S 中的每个 Token 的词性标签如下：["The": DEP（冠词）, "Eiffel": PROPN（专有名词）, "Tower": PROPN（专有名词）, "is": AUX（助动词）, "located": VERB（动词）, "in": ADP（介词）, "Paris": PROPN（专有名词）, ".": PUNCT（标点符号）]。

句子边界检测由 sentencizer 组件完成，该组件基于规则引擎动态划分句子边界，同时由 parser 组件中的统计分割器预测句子边界，增强对嵌套引号内子句等复杂结构的精准识别能力。在实际使用过程中，我们发现 LLM 输出中可能存在非标准标点，我们启用备用 sentencizer 组件，通过正则表达式匹配强制分割非常规文本。经过实验分析，经过上述的混合句子分割器，我们能将几乎所有的 LLM 输出的文本较为精准地分割成独立的句子单元。在本例中，句子分割输出结果为“The Eiffel Tower is located in Paris.”。当生成结果 A 为“The Eiffel Tower is in Paris. It is a famous landmark.”时，该分割器就会将其分解为“The Eiffel Tower is in Paris.”“It is a famous landmark.”两个独立的句子单元。

为了验证方法的有效性，我们对该模块进行了 500 句由 ChatGPT，DeepSeek 等主流 LLM 生成的文本验证。结果显示，spaCy 句子分割解析结果与人工标注结果保持 95.2%的一致性，我们观察后推测其主要误差来源于对话式 AI 输出中常见的省略结构。

依存句法分析：依存句法分析的核心任务是确定分割出的独立句子单元中各个单词之间的依赖关系，尤其是识别主语、谓语和宾语等基本成分，并构建这些成分之间的依赖树，提取句法结构进而支持文本结构分类。

基于上述的句子分割结果，我们调用 spaCy 的 parser 组件实现依存句法分析。首先，该模块以 Transformer 生成的上下文词嵌入作为输入。得益于 Transformer 所生成的动态词符表征，该模块具备了强大的上下文感知能力。

接下来，通过基于转移的解析器构建语法树。解析器通过采用动态 Oracle 策略，依次执行 SHIFT、REDUCE、LEFT-ARC、RIGHT-ARC 动作，生成头词 (Head) 与依存关系标签并形成依存树。在本例中，对 A 的子句 a 进行解析时，解析器正确识别“located”为根节点 (ROOT) ，表示分割出独立句子单元的**核心谓语**。接着，标注各词符的依存关系并形成依存树 T 如图 3-16 所示，该依存树 T 的依存关系解析为：

["The → det(冠词修饰)→ Tower", "Eiffel → compound(复合名词)→ Tower",

"Tower → nsubjpass(被动主语)→ located", "is → auxpass(被动助动词) → located",

"located → ROOT(根节点) → located", "in → prep (介词修饰)→ located",

"Paris → pobj(介词宾语)→ in", ". → punct(标点符号)→ located"]。

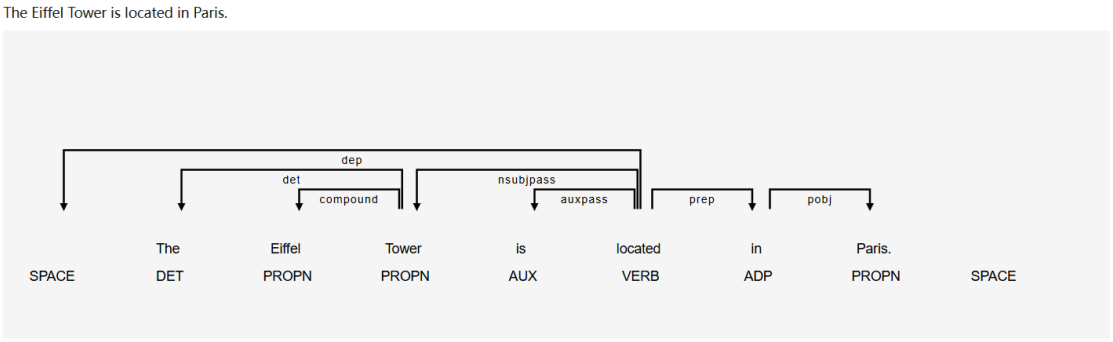


图 3-16 依存树一览图

文本结构分类：在介绍文本结构分类模块之前，我们首先对获取的数据进行整合与定义：LLM 的输出回答 A 经过句子边界检查模块处理后，得到 A 的句子数量 α ，并将 A 分割为 n 个独立的句子单元 a_i（i=1,2,3...n）。随后，借助依存句法分析模块，为每个句子单元 a_i 生成对应的依存树 T_i。在此基础上，我们统计文本 A 中所有依存树的核心谓语 (ROOT) 数量 β 。该核心谓语通常代表句子的主要谓语或中心动词，直接能够反映文本的语义结构。

基于上述定义，我们进一步设计文本结构分类规则，以区分单命题文本和多命题文本。在该任务中，多命题文本是指包含**多个独立的语义单元**的文本，每个语义单元通常对应一个完整的句子，表达一个完整的思想或事实。相应地，单命题文本仅包含**一个独立的语义单元**，通常为单句，表达一个完整且单一的思想或事实。

具体而言，当 A 为"The Eiffel Tower is located in Paris. It is a famous landmark." 时，文本 A 被划分为两个句子单元 a_1 和 a_2，分别生成依存树 T_1 和 T_2。统计结果显示，T_1 和 T_2 的两个核心谓语分别为"located"和"is"。因此，句子 A 的 α 值为 2， β 值也为 2，两个句子拥有独立的依存结构，分别表达了两个不同的想法或事实。由此，我们判定 A 为多命题文本。

同理，当 A 为"The Eiffel Tower is located in Paris. It is a famous landmark. It attracts millions of visitors each other. "， α 值为 3， β 值也为 3，三个句子均具有独立的依存结构，显然，A 同样属于多命题文本。

经过大量的实验，我们发现 α 的值通常小于等于 β 的值，这与语言表达的基本规律相符。通俗来讲，一个完整的句子单元中至少包含一个核心谓语（即 $\beta \geq 1$）。故此，考虑到 LLM 幻觉检测任务对处理效率的要求，我们采用简化的分类策略：只需要统计 A 的句子数量 α ，**当 $\alpha > 1$ 时，直接将 A 划分为多命题文本**（此时 $\beta \geq \alpha > 1$）。

进一步地，针对单命题文本的判定，我们采用更加严格的策略。文本 A 被归类为**单命题文本**，当且仅当 **$\alpha = 1$ 且 $\beta = 1$** 时成立。举例来说，文本"The Eiffel Tower is located in Paris."中， α 值为 1 且 β 值也为 1，语义集中，结构单一，我们将其判定为单命题文本。

然而，值的注意的是，不同于多命题文本划分方式，句子数量 α 为 1 并不意味着文本 A 为单命题文本。例如，当 A 为"The Eiffel Tower is located in Paris, and it is a famous landmark."时，句子数量 α 值为 1，但 β 值为 2，即一个句子中含有两个核心谓语“located”和“is”，表明该句内部包含两个相对独立的事实或陈述，实际上应被视为多命题文本。

综上所述，为确保文本结构分类的准确性，我们的判定规则为：

当 $\alpha > 1$ 时，文本 A 为多命题文本；

当 $\alpha = 1$ 且 $\beta = 1$ 时，文本 A 为单命题文本；

当 $\alpha = 1$ 且 $\beta > 1$ 时， 文本 A 为多命题文本。

3.2.2 语义熵

在大型语言模型的幻觉检测研究领域，基于不确定性量化的方法已展现出其在检测精度和速度方面的显著优势[17]。相较于依赖模型内部状态分析的方法，该方法在开放领域问题方面表现出更佳的适应性，并展现出更广泛的普适性[18]。

然而，目前基于不确定性度量的应用多依赖于朴素熵的方法，这是一种基于生成文本的词序列直接计算不确定性的方法。它通过计算生成答案的词序列的联合概率分布来衡量不确定性，这种方法未考虑语义等价性，因此可能会高估不确定性，同时它更适合于简单的文本生成任务，对于长文本内容时往往效率较低。

受目前研究的启发[18][19]和香农信息论的学习,我们采用了一种更高级的不确定性衡量方法，它通过语义聚类来计算不确定性。其核心理念在于依据生成文本的语义内涵而非特定的词汇序列，通过计算生成内容在语义层面的差异性——即语义熵，来量化其不确定性。先前的研究[20][21][22]表明高语义熵表示模型对生成的内容存在高不确定性，可能产生虚构内容。通过这种方法，我们能有效的检测大语言模型输出的不一致性，从而达到检测幻觉的目的。

同时，我们采用的语义熵在大语言模型输出长文本时亦能展现出良好的效果。为了兼顾轻量化和检测精度，我们对大语言模型生成的长、短文本内容的语言熵

计算采用了相似但有所区别的方法。接下来，将从**单命题**和**多命题**幻觉检测两个方面进行详细介绍。

3.2.3 单命题回答语义熵计算

单命题生成是指在大语言模型中生成内容的篇幅较短，通常表达单一命题。例如，回答一个具体问题时，模型的输出可能是一个简短的句子，其核心意思相对明确。常见于问答场景。对于单命题回答的幻觉检测，本研究通过计算其语义的不一致性来实现。

首先，不确定性的一种度量是输出分布的预测熵，它测量给定输入的输出信息。输入句子 x 的预测熵（PE）是给定 x 的实现 Y 的输出随机变量 Y 的条件熵（H），如公式（6）所示：

$$PE(x) = H(Y|x) = -\sum_{y} P(y|x) lnP(y|x) \tag{6}$$

其中，x 是用户输入，Y 是 LLM 输出的集合，y 是每一条输出。

低预测熵表示输出分布高度集中，而高预测熵表示输出存在差异。

在计算预测熵时，若将模型对其答案含义的不确定性与用于表达该含义的确切文字的不确定性混为一谈，可能会导致误判，从而影响幻觉检测的精度。例如，即便不存在幻觉问题，大型语言模型也可能对含义相同的结果给出不同描述的回答[17]。

因此，为了达到检测幻觉的目的，大型语言模型对语义的不确定性比用于表达这些含义的确切符号的不确定性更为关键。

本研究提出的语义不确定性方法，旨在仅估计大型语言模型对其生成意义的不确定性，而非文字本身的选择。为实现此目标，本研究引入了一种算法，该算法通过意义聚类模型代，进而计算语义不确定性。在高层次上，该方法涉及以下**三个步骤**：

1. **生成**:从给定上下文 x 的 LLM 的预测分布中获得回答的样本输出序列。

2. **聚类**:我们基于双向蕴涵的聚类算法，按意义对序列进行聚类。

3. **熵估计**:通过求和序列的概率来估计语义熵，这些序列具有在公式（7）计算之后具有含义并计算其语义熵的概率。

$$P(c|x) = \sum_{s \in c} P(s|x) = \sum_{s \in c} \prod_{l} P(s_i|S_{<i}, x) \tag{7}$$

如图 3-17 所示

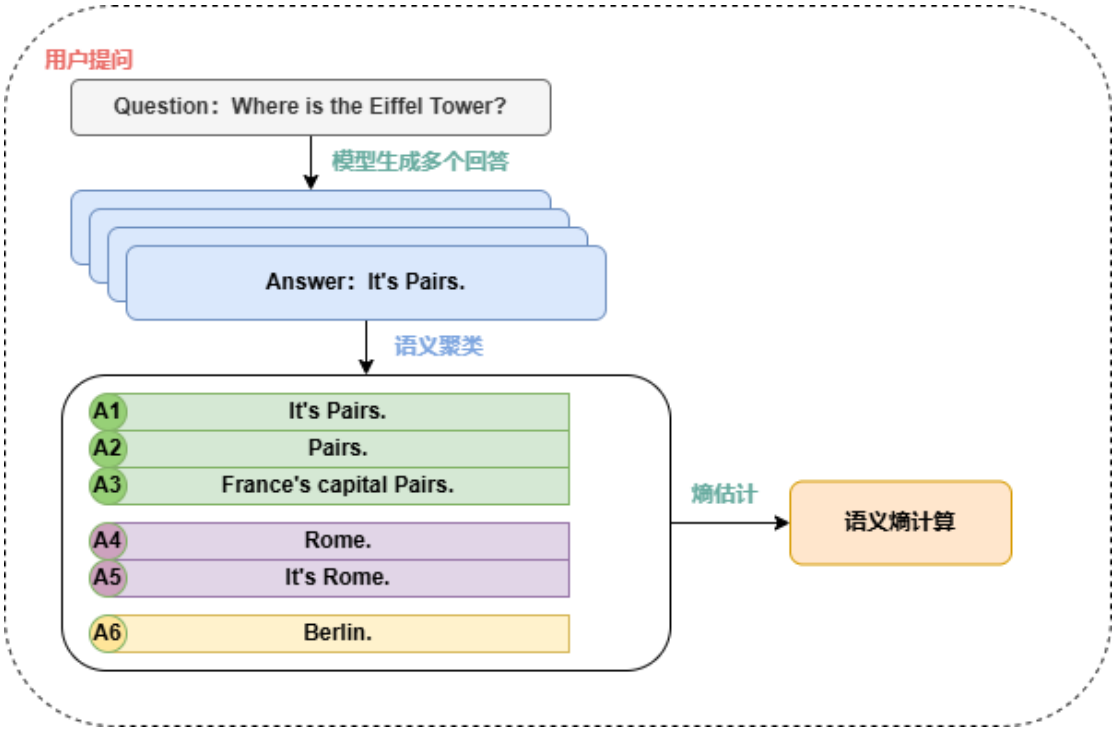


图 3-17 单命题回答语义熵计算流程

具体步骤如下：

1.生成多个样本输出序列：

在本研究中，我们采用大语言模型生成一组答案，以探究模型在不同随机种子下的生成行为。具体而言，给定上下文 x 作为模型输入，我们对生成序列$\{s^{(1)},\ldots,s^{(M)}\}$，进行采样，并记录每个序列的条件概率$\{P(s^{(1)}|x),\ldots,P(s^{(M)}|x)\}$。

为了确保采样结果的多样性，我们仅改变随机种子(Random Seed)，而保持其他条件不变。实验结果表明，该方法对采样方案的细节并不敏感。

在实现过程中，我们采用温度（temperature）为 1 的设置，并结合核采样（nucleus sampling，P=0.9）和 top-K 采样（top-K sampling，K=50）进行采样。

此外，为了评估模型对给定上下文的“最佳生成”能力，我们还在低温（temperature＝0.1）下对单个序列进行采样。低温设置显著提高了高概率令牌的采样概率，从而为模型生成的最可能序列提供了一种估计。这一过程不仅有助于评估模型的准确性，还揭示了温度参数在控制生成结果随机性与确定性之间的平衡作用。

2.通过语义等价进行聚类：

为了准确估计语义熵，我们需要将模型生成的输出进行聚类，使其归属于语义相同的类别。这一过程可以被形式化为“语义等价”关系，即当两个句子表达相同或相似的语义时，它们之间存在一种等价关系。以下是对该过程的数学化描述和理论阐述：

设语言中所有标记的集合为T，所有可能的长度为N的标记序列空间为$S_N \equiv T^N$。

其中，T表示语言中所有可能的标记（token）的集合。N表示序列的长度，即一个序列中包含的标记的数量。S_N表示所有可能的长度为 N 的标记序列的集合。换句话说，S_N是由集合T中的元素构成的所有长度为N的序列的集合。T^N与S_N等价，表示从集合T中选择N个标记的所有可能组合。

需要注意的是，N可以任意增大，以涵盖任何可能的句子长度。此外，标记序列中可以包含“填充”标记，该标记出现在句子结束标记之后的所有位置。

对于任意句子$s \in S_N$，其由一系列标记$s_i \in T$组成，并且每个句子都对应一个特定的语义。

在此基础上，我们引入一个语义等价关系 $E(\cdot,\cdot)$，用于判断任意两个句子是否具有相同的语义。等价关系是自反的、对称的和传递的。

集合上的任何等价关系都对应于一组等价类。每个语义等价类 C 包含的句子可以被视为表达了相同的语义。换言之，对于语义等价类的空间 C，集合$c \in C$中的句子在许多语境中可以被视为语义相似，满足一定条件，见公式（8）

$$\forall s, s' \in c: E(s, s') \tag{8}$$

因此，我们可以通过检查新句子是否与已聚类的句子具有相同的语义来构建这些语义等价类。如果新句子与某个已聚类的句子语义相同，则将其归入该类。通过这种方式，我们能够系统地对模型生成的输出进行语义分类，从而为进一步的语义熵估计提供基础。

在本研究中，我们采纳了双向蕴含（Bidirectional Entailment）的概念来形式化语义等价关系 $E(\cdot,\cdot)$，这一概念在语言学[25]和自然语言处理[26][27][28]领域具有深远的研究历史和广泛的应用基础。具体而言，我们认为两个序列 s 和 s' 仅当它们相互蕴含，即在逻辑上互为隐含关系时，方可视为语义等价。

例如，语句“法国的首都是巴黎”与“巴黎是法国的首都”在逻辑上互为蕴含，因此它们表达了相同的语义内容。这种蕴含关系是双向的，即如果 s 蕴含 s' 且

s' 蕴含 s，则 s 和 s' 在语义上是等价的。

然而，值得注意的是，双向蕴含并不总能完全保证两个语句的语义等价性。在某些情况下，即使两个语句在逻辑上互为蕴含，它们也可能因为语境、语用或其他语义因素的差异而不完全等价。

因此，我们进一步探讨软等价的概念，以更细致地分析和处理这类情况。

软等价允许在一定程度的语义差异下，仍然认为两个语句在特定的语境或应用场景中是等价的。例如，“巴黎”不蕴含“法国的首都是巴黎”，因为“巴黎”不是一个没有上下文的陈述句。但是在“法国的首都是哪里?”的上文条件下，“巴黎”所表示的意思和“法国的首都是巴黎”是一致的。这种灵活性对于提高自然语言处理任务的准确性和鲁棒性具有重要意义。

通过引入双向蕴含的概念，我们能够更精确地定义和识别语句间的语义等价关系，为自然语言理解和生成任务提供坚实的理论基础。同时，我们也认识到在实际应用中需要考虑更复杂的语义因素，以实现更全面和准确的语义分析。

接下来，我将介绍本项目的蕴含检测方法。蕴涵检测作为自然语言推理（NLI）领域的一个关键研究对象[29]，已经吸引了大量的研究关注。本项目使用构建prompt，来提示 LLM 进行蕴含检测，如图 3-18 所示。

Prompt 1：蕴含检测

输入：序列$s^{(i)}$和序列$s^{(j)}$

步骤： **if** $s^{(i)} \rightarrow s^{(j)}$ **then**

$left \leftarrow M(s^{(i)}, s^{(j)})$

if $s^{(i)} \leftarrow s^{(j)}$ **then**

$right \leftarrow M(s^{(j)}, s^{(i)})$

图 3-18 蕴含检测Prompt

在本研究中，我们依赖于先进的语言模型来预测语句间的蕴涵关系。例如，DeBERTa-Large-MNLI 模型，它已经被训练来预测语句间的蕴涵关系。此外，通用的大型语言模型，如 GPT-3. 5，也能够在给定合适的提示的情况下预测蕴涵。这些模型通过深度学习技术来理解和预测语句间的逻辑关系，从而在自然语言处理任务中发挥重要作用。

随后，本研究采纳了图 3-19 中详述的算法框架，依据句子间是否满足双向蕴含关系进行聚类分析。

算法 1：双向蕴含聚类算法

已知：上下文x，序列集合$\{s^{(2)},\dots,s^{(M)}\}$,自然语言推理(NIL)分类器$M$，意义集合$C=\{\{s^{(1)}\}\}$

步骤：for $2 \le m \le M$ **do**

for $c \in C$ **do**

设$s^{(c)} \leftarrow c_0$ //c_0是类别 c 中的第一个序列

计算$left \leftarrow M(s^{(c)},s^{(m)})$ //判断$s^{(c)}$是否蕴含$s^{(m)}$

计算$right \leftarrow M(s^{(m)},\ s^{(c)})$ //判断$s^{(m)}$是否蕴含$s^{(c)}$

if $s^{(c)}$蕴含$s^{(m)}$ **and** $s^{(m)}$蕴含$s^{(c)}$ **then**

$c \leftarrow c \cup s^{(m)}$ //将$s^{(m)}$加入类别 c

end if

end for

$C \leftarrow C \cup \{s^{(m)}\}$ //$s^{(m)}$如果不在任何类别，则创建新类别 C

end for

return C

图 3-19 双向蕴含聚合算法

需要指出的是，在判定某一序列是否应归入现有簇时，仅需验证该序列是否与簇内的任一现有序列（我们通常选择簇中的第一个序列作为代表）存在双向蕴含关系，这是基于语义等价关系的传递性质。具体而言，若待分类序列未能与任一现有聚类展现出语义等价性，则将其视为一个独立的聚类实体。

在聚类过程中，我们采用了一种基于蕴含关系的聚类策略，该策略的核心思想是：如果两个句子在语义上相互蕴含，则它们在语义空间中应被归为同一类。这种方法不仅能够捕捉到句子间的直接蕴含关系，还能通过蕴含关系的**传递性**，将间接蕴含的句子也纳入同一聚类。这有助于更全面、更细致地揭示句子间的语义关联，为语义分析和知识发现提供新的视角。

同时，本研究也注意到，并非所有的句子都能明确地归入某一现有聚类。对于那些无法与现有聚类形成双向蕴含关系的句子，我们选择将其单独作为一个聚类。这种做法既保证了聚类结果的准确性，又避免了过度泛化，有助于维护聚类分析的精细度和解释力。如图 3-20，Answer6 无法与已经存在的 c_0 和 c_1 归于一类，则自己单独作为类 c_2 存在。

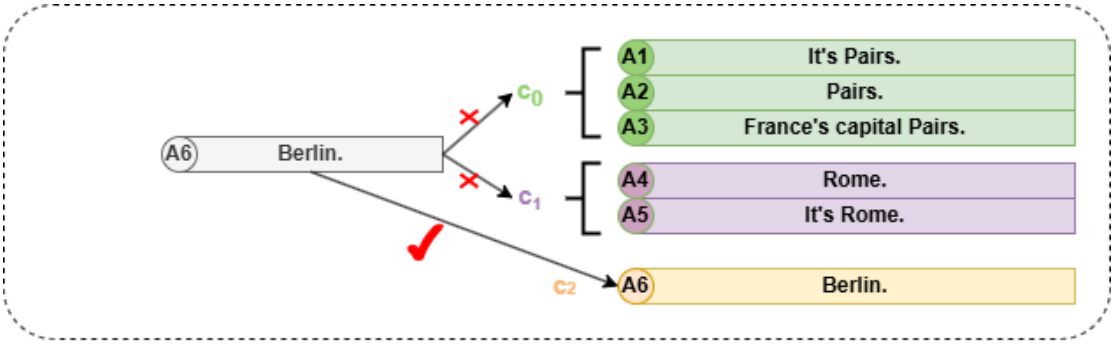


图 3-20 A6单独聚类

3.计算语义熵：

在确定表示相同概念的生成序列的类别后，我们可以通过对所有可能的标记序列的概率求和来估计大语言模型生成的序列属于给定类别的可能性，这些标记序列可以被认为是表达了相同的意义。这种方法允许我们计算生成序列与特定语义类别的关联概率，从而评估序列在语义上的相似性。通过计算所有可能的标记序列的联合概率分布，我们能够量化 LLM 生成特定语义内容的概率，见公式（9）

$$P(c|x) = \sum_{s \in c} P(s|x) = \sum_{s \in c} \prod_{l} P(s_i|s_{<i}, x) \tag{9}$$

其中，c 指语义相同的序列聚类；s 是 c 中的序列；类别 c 的概率可以通过计算类别中所有序列的概率之和来得到。而每个序列的概率又可以通过计算序列中每个标记的条件概率的乘积来得到。

在形式化框架中，我们将模型的输出视为一个随机变量，其样本空间定义为所有可能的语义类别的集合 C，并且 C 是标准样本空间 S 的一个子 σ 代数。在此基础上，我们可以对语义熵（Semantic Entropy，SE）进行估计，将其视为在语义类别分布上的熵的度量，见公式(10)(11)：

$$SE(x) = -\sum_{c} P(c|x)\, logP(c|x) \tag{10}$$

$$= -\sum_{c} \left[\left(\sum_{s \in c} P(c|x) \right) \log \left(\sum_{s \in c} P(s|x) \right) \right] \tag{11}$$

在进行语义熵的计算时，我们面临一个主要的挑战：由于语义类别的数量可能非常庞大，我们无法直接访问每个可能的意义类别 c。

因此，我们无法直接计算所有可能的意义类别的概率分布。相反，我们只能从模型诱导的序列生成分布中对 c 进行采样。这样会导致方法的适配性降低，不

能通用于不开源的大语言模型。

为了解决这个问题，我们采用 Rao-Blackwellized Monte Carlo 积分方法来估计公式(8)中的期望。这种方法通过减少方差来提高蒙特卡洛估计的效率，从而在语义等价类 C 上进行更准确的期望估计。

具体来说，我们利用 Rao-Blackwell 化技术来改进标准的蒙特卡洛积分，通过条件化某些已知的统计量来减少估计的方差，从而提高估计的准确性和效率，见公式（12）

$$SE(x) \approx -\sum_{i=1}^{|C|} P(C_i|x) log P(C_i|x) \tag{12}$$

其中$P(C_i|x) = \frac{P(c_i|x)}{\sum_c P(c|x)}$, 确保了$\sum_i P(C_i|x) = 1$。这一归一化步骤是必要的，以避免因长度归一化导致的聚类概率超过 1，从而避免退化问题。我们的主要方法通过公式(12)提供了语义熵的估计器。

这种方法在处理复杂的语义聚类问题时特别有用，因为它允许我们在无法直接访问所有可能的语义类别的情况下，仍然能够有效地估计语义熵。

在序列概率不可获取的情况下，我们引入了一种称为“**离散语义熵**”的语义熵变体。

该方法直接从每个聚类中的生成数量来近似$P(C_i|x)$ ，忽略了标记概率。具体来说，我们近似$P(C_i|x)$为$\sum_1^M \frac{l_C=C_i}{M}$，即属于该聚类的所有采样答案的比例。这种方法假设每个实际生成的输出具有相同的概率，从而将底层分布估计为类别经验分布。根据大数定律，当采样数量 M 趋于无穷大时，该估计器收敛于公式(13)。

$$SE(x) \approx -\sum_{i=1}^{|C|} P(C_i|x) log P(C_i|x) \tag{13}$$

我们的实验结果表明，离散语义熵产生了与语义熵类似的性能。

3.2.4 多命题回答语义熵计算

多命题回答是指在大语言模型中生成内容的篇幅较长，特别是生成传记等叙述性质的文本。这类长文本（如段落或篇章）通常包含多个命题，这些命题可能部分相关或完全独立。例如，在一个段落中，可能同时涉及人物的出生、职业、成就等多个方面。

单命题回答的语义较为集中，适合直接采样和聚类；而多命题回答包含多个命题，直接处理会导致语义噪声增加，无法准确评估不确定性。直接对整个段落进行采样和聚类会引入大量无关的语义变化，导致无法准确评估模型对每个命题的不确定性。

为了应对这种复杂性，本项目提出将长文本分解为具体的事实单元，每个事实单元对应一个独立的命题。例如，从一个段落“某人出生于 1911 年，从事摩托赛车手工作…”中提取出“某人于 1911 年出生”“某人是一位摩托车赛车手”等事实单元。如图 3-21 所示：

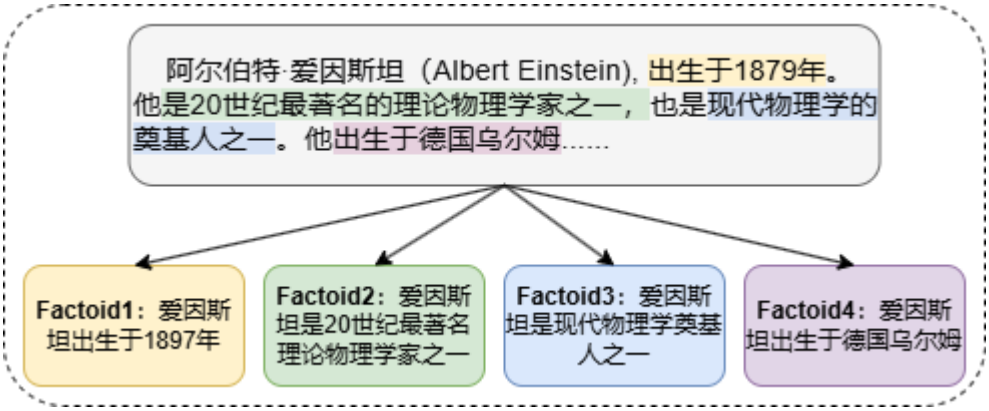


图 3-21 多命题事实分解

对于每个事实单元，重新构造可能产生该事实的问题，并对这些问题分别采样生成回答。然后计算每个问题的语义熵，最终将这些语义熵汇总，得到对整个段落的不确定性评估[18]。我们这种方法的核心在于将长文本的复杂性分解为多个简单的短文本问题，从而利用短文本检测方法的优势。

总的来说，对于大语言模型生成多事实论述中的幻觉问题检测，包括以下步骤：

1. **原子事实分解：**使用 LLM 自动将段落分解为具体的事实主张(不一定与原文相同)。

2. **构造对应问题和重新采样：**对于每个分解的原子事实，使用 LLM 自动构建可能产生该原子事实的 Q 问题。对于每个问题，提示原 LLM 再次生成 M 个答案。

3. **聚类：**将 M 个再生成答案和最初的事实主张进行聚类。

4. **语义熵估计：**对于每个问题，计算答案的语义熵，包括最初的事实主张。对问题的语义熵求平均值，得出原始事实主张的分数。

整体流程见图 3-22：

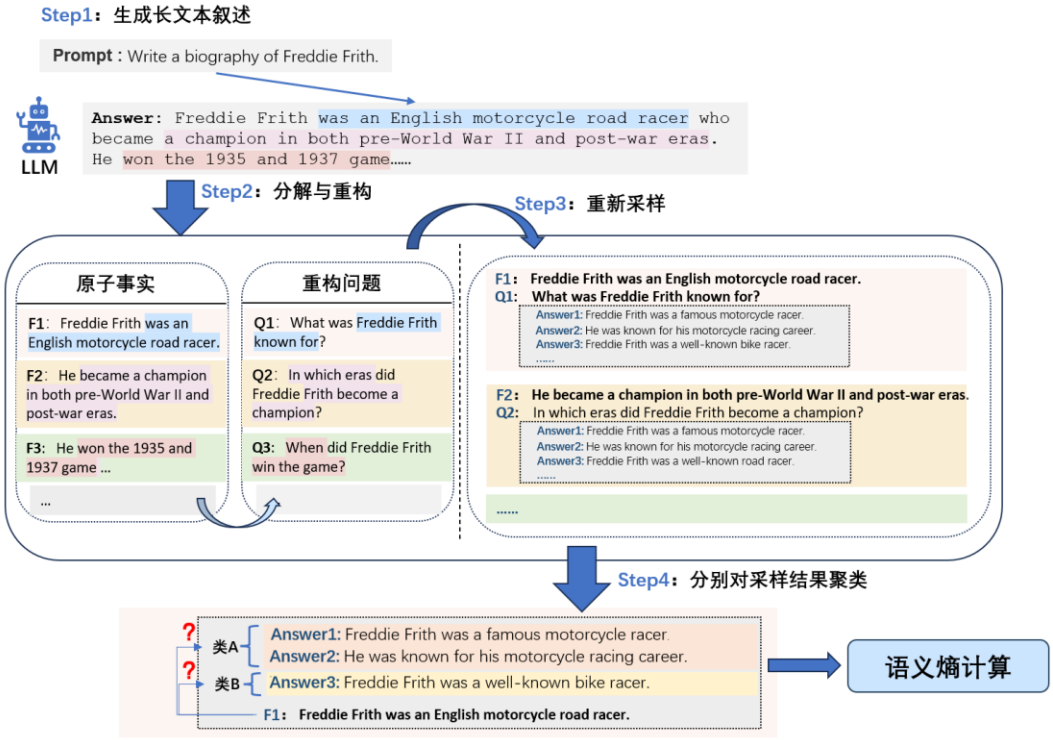


图 3-22 多命题回答语义熵计算流程

分解长文本为事实单元：

我们使用其他大型语言模型来提取原子事实 （factoids） 而不是直接使用生成这些事实的原始模型。

我们使用以下提示将段落分解为原子事实，见图 3-23：

Prompt 2：分解原子事实

输入：根据下面内容{text so far}

要求：请列出上述内容中包含的具体事实命题{factoids}。要完整，不要遗漏任何事实主张。把每一个主张作为一个单独的句子{sentence}，用一个单独的要点来表达。

输出：$\{\{sentence\ 1\} \leftarrow \{factoid\ 1\}\}, \ldots, \{\{sentence\ n\} \leftarrow \{factoid\ n\}\}$

图 3-23 分解原子事实Prompt

这种方法可以提供独立的验证、减少幻觉的影响、利用模型的特定能力，并提高系统的多样性和鲁棒性。这种方法不仅能够提高事实提取的准确性，还能增强系统的灵活性和可扩展性，使其更适合于各种实际应用场景。

构造对应问题和重新采样：

在长文本幻觉检测中，针对每个事实单元（factoid）自动生成问题是一个关键步骤，但这一过程存在显著的挑战。

具体而言，生成的问题可能无法精准地覆盖事实的所有关键方面，从而导致部分重要信息被遗漏。这种问题生成的不精准性是程序错误的主要来源之一，尤其是在事实单元包含多个重要细节时。

为了提高问题的针对性和多样性，我们采用了以下策略：

多轮问题生成：对于每个事实单元，我们首先生成三个问题，这一数量的选择旨在鼓励问题的多样性，使得每个问题能够针对事实的不同方面。然而，单次生成可能无法完全覆盖事实的所有关键细节。因此，我们进一步扩展了这一策略，通过执行相同的提示两次，总共生成六个问题。这一改进显著提高了对事实单元的覆盖范围，减少了遗漏关键信息的风险。

简短答案的要求：在生成问题时，我们明确要求模型提供简短的答案。这一要求的提出是基于对当前版本的 GPT-4 的观察：在没有明确指示的情况下，该模型往往会生成冗长、复杂且高度对冲的答案。这种冗长的答案不仅增加了后续处理的复杂性，还可能引入不必要的噪声，干扰事实的准确提取和评估。

通过要求简短答案，我们能够引导模型更直接地聚焦于事实的核心内容，从而提高后续语义熵计算的准确性和效率。

具体而言，我们为来自分解的每个事实生成六个问题。通过以下方式提示（prompt）模型来生成这些问题。见图 3-24：

Prompt 3：重构事实问题

输入：while $i \leq 2$

for $1 \leq m \leq n$ do

$\{\{sentence\ m\} \leftarrow \{factoid\ m\}\}$ //依次输入事实单元

要求：根据提供的事实单元句子，构建三个可能的问题{Question}。要符合逻辑，要语言简短，要能根据这一问题得出提供的事实单元句子。

$i = 1$ then

i++ //循环两次

输出：$\{\{question\ 1\} \leftarrow \{factoid\ 1\}\}, \ldots, \{\{question\ 6\} \leftarrow \{factoid\ 6\}\}$

图 3-24 重构事实问题Prompt

随后，针对每个问题，我们采用以下精心设计的提示来生成三个新的回答，见图 3-25：

Prompt 4：重新生成回答

输入：for $1 \le m \le 6$ do

$\{\{question\ m\} \leftarrow \{factoid\ m\}\}$　　//依次输入重构的问题

要求：请回答这个问题。不要用完整的句子回答。回答时尽量使用少量词语，例如一个名字、一个地点或事物，要准确。

输出：for $1 \le i \le 6$

for $1 \le j \le 3$ $\{\{answer\ i.j\} \leftarrow \{factoid\ i\}\}$

图 3-25 重新生成回答Prompt

通过设计 prompt，大大增加了我们项目的轻量化。

聚类：

接下来对每个问题生成的三个回答，结合原来分解的事实一起进行聚类。

在单命题蕴含检测中，利用大语言模型构建提示的方法表现出色，尤其是在蕴含估计任务中，通过提示 LLM 可以有效地指导小嵌入器寻找文本簇。

然而，在多命题蕴含检测任务中，情况有所不同。多命题蕴含检测需要处理的文本数量较多，且文本之间的关系更为复杂。使用 LLM 辅助的方法虽然理论上可行，但在实际应用中会面临显著的时间和资源消耗问题。例如，CLUSTERLLM 框架在利用 LLM 进行文本聚类时，需要通过复杂的提示和采样策略来优化性能。这种复杂性在多命题蕴含检测中会导致计算成本大幅增加，从而与我们追求轻量化的目标相悖。

在进行原始声明与再生答案之间的语义蕴涵评估时，我们选用了 DeBERTa 蕴涵预测模型[49]。其高效的编码机制和优化的架构使其能够快速准确地判断文本之间的蕴含关系。经实证研究发现，相较于其他方法，DeBERTa 在训练集上的 AUROC 值更高，表现出更优的性能。DeBERTa 模型如图 3-26 所示。

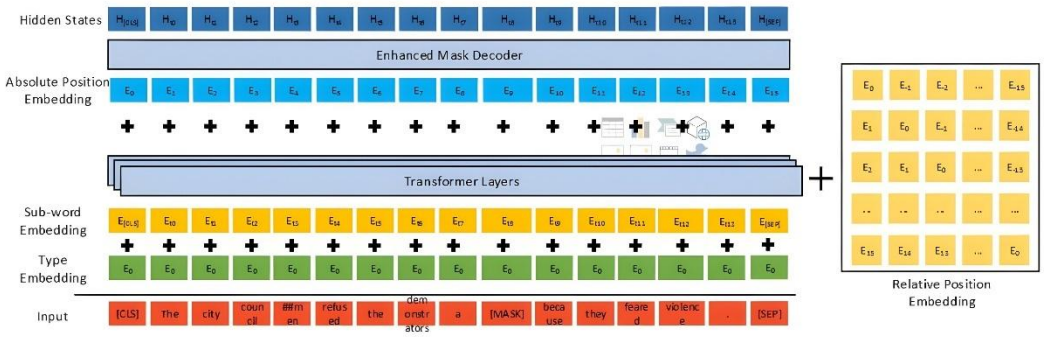


图 3-26 DeBERTa模型图

将需要评估的两个声明分别作为输入文本，通常会将其中一个文本作为前提(premise)，另一个作为假设(hypothesis)，并按照一定的格式进行组合，如“[CLS] 前提 [SEP] 假设 [SEP]”，然后通过 DeBERTa 的分词器对其进行分词和编码。

将编码后的输入序列输入到 DeBERTa 模型中，模型会利用其独特的解耦注意力机制 (Disentangled Attention Mechanism) 和增强的掩码解码器 (Enhanced Mask Decoder) 等结构，对输入文本进行编码，提取文本的语义特征。解缠注意力机制将每个单词的内容和位置分别用两个向量表示，并分别计算单词之间的内容相关性和相对位置相关性，从而更准确地捕捉文本的语义信息。

模型的输出层会根据提取到的语义特征，对输入文本之间的蕴含关系进行判断。通常会输出一个概率分布，表示输入文本之间属于“蕴含”、“中性”或“矛盾”关系的概率。在一些特定的模型设置中，可能会移除“中性”输出，仅保留“蕴含”和“矛盾”两种结果。

根据模型输出的概率分布，确定两种声明之间的语义蕴含关系。例如，如果“蕴含”关系的概率较高，则可以认为再生答案在语义上支持原始声明。这种评估结果可以应用于多种场景，如文本一致性检查、信息验证、问答系统中的答案评估等。

同样的，如果两个声明双向蕴含，我们就把它们视为一类。

对于不在任何已知类的声明，将其单独作为一类。

计算语义熵：

对每个重构问题的三个新回答和初始事实根据语义进行聚类之后，可以根据聚类结果，计算每个问题的语义熵。

根据聚类结果，计算每个问题的语义熵。语义熵的计算公式(14)：

$$SE(x) = -\sum_{c \in C} P(c|x)\, logP(c|x) \tag{14}$$

其中，$P(c|x)$ 是生成的回答属于某个语义类 c 的概率。具体计算方法是将每个类中所有回答的概率相加，然后计算这些类的概率分布的熵。

将每个问题的语义熵汇总，得到整个段落的语义熵。见公式(15)：

$$SE_{paragraph} = \frac{1}{Q}\sum_{q=1}^{Q} SE(q) \tag{15}$$

其中，Q 是问题的数量。

3.2.5 知识库

语义熵计算是一种通过提示同一语言模型进行多次响应并识别其输出不一致性来检测幻觉的方法。该方法基于黑盒模型，无需任何关于模型内部结构的知识，仅依赖于大语言模型的输出即可检测出幻觉部分。与传统的白盒方法（依靠对大语言模型内部网络的修改）相比，语义熵计算在计算速度上具有显著优势。

然而，由于缺乏对大语言模型内部知识的了解，在对模型进行多次提问时，可能会出现内容一致但完全错误的输出，即低熵情况。在这种情况下，仅依靠语义熵计算将无法有效检测幻觉。换言之，当幻觉内容具有一致性时，仅依赖模型的内在知识可能会导致检测失败。

所以我们对于低熵下的可能存在幻觉问题的回答再次进行知识库检索，得到相关的事实论述，并重新聚类进行语义熵的计算。以内部知识结合外部知识的方法取得了良好成效。见图 3-27：

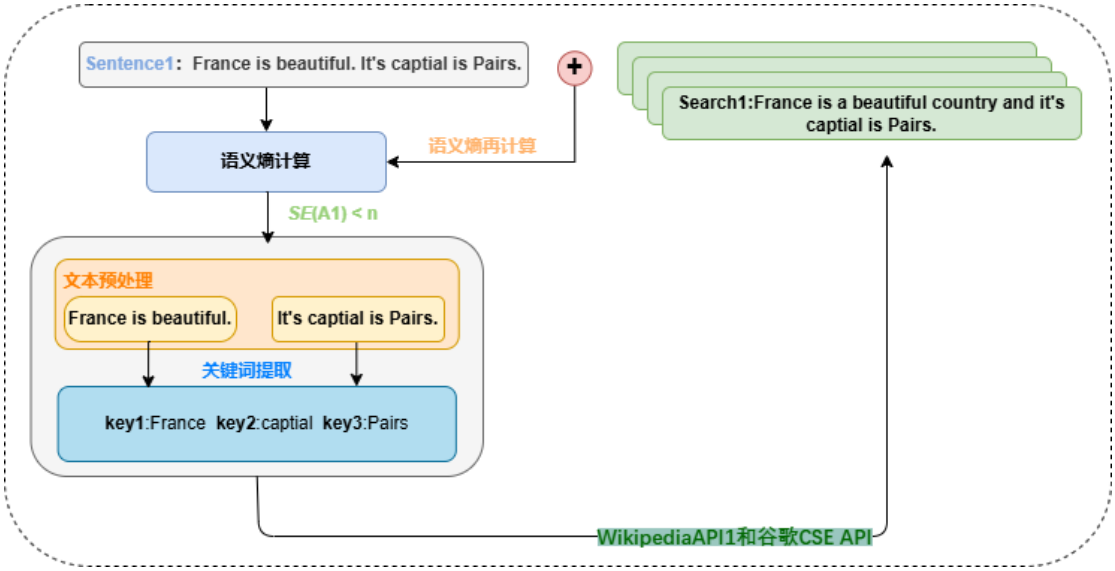


图 3-27 低熵回答结合外部知识库

首先对于存在相同幻觉隐患的低熵输出情况进行关键词提取，从 LLM 的输入文本中识别出最能代表文本主题和核心内容的词语或短语。这些关键词将用于后续的外部知识检索，以获取与输入文本相关的背景信息和事实性数据。

我们使用 YAKE（Yet Another Keyword Extractor）的思想[36]进行关键词提取。

提取关键字的四个主要流程：文本预处理——>特征提取——>单个词权重计算——>候选关键字的生成，其中最为关键的莫过于特征提取过程。

文本预处理就是对文档进行简单的分词，按照标点或者特殊的符号。

对于特征提取，我们采用了 5 种常见的特征，Casing、Word Position、Word Frequency、Word Relatedness to Context、Word DifSentence。

Casing：特别关注以大写字母开头的任何单词（不包括句子开头的字母）或任何首字母缩略词（即，该单词的所有字母都是大写），前提是这些单词往往更相关。我们不计算它们两次，只考虑它们中的最大值。见公式（16）：

$$W_{Case} = \frac{\max\left(TF(U(w)), TF(A(w))\right)}{log_2\left(TF(w)\right)} \tag{16}$$

其中，$TF(U(w))$是候选词w以大写字母开头的次数，$TF(A(w))$是候选词w被标记为首字母缩略词的次数，而$TF(w)$是w的频率。

Word Position：考虑单词出现的句子位置可能是关键词提取过程的一个重要特征，因为文档（尤其是科学和新闻出版物）的早期部分往往包含大量相关关键词。见公式(17)：

$$W_{Position} = \log_2(\log_2(2 + Median(Sen_w))) \quad (17)$$

其中，Sen_w表示单词w出现在句子集的位置，$Median$是中值函数。结果是一个递增函数，当单词位于文档末尾时，值趋于平稳增加，这意味着单词出现在文档开头的频率越高，其$W_{Position}$ 值越小。相反，更经常位于文档末尾的单词（可能不太相关）将被赋予更高的 $W_{Position}$ 值。注意，等式中考虑值 2，以保证$W_{Position}$>0。

Word Frequency：该特征指示文档中单词 w 的频率。它反映了一种理念，即频率越高，单词越重要。为了防止长文档中出现偏向高频的情况，单词 w 的 TF 值除以频率均值 MeanTF。我们的目的是对所有高于平均值的单词进行评分（由标准偏差给出的分散度平衡）。见公式(18)：

$$W_{Freq} = \frac{TF(w)}{MeanTF + 1 * \delta} \quad (18)$$

Word Relatedness to Context:量化了一个词与停止词特征相似的程度。为了计算这个度量，我们借助于出现在候选词左侧（和右侧）大小为 n 的窗口中的不同项的数量。与候选词（两侧）同时出现的不同词的数量越多，候选词可能就越无意义。见公式(19)：

$$W_{Rel} = \left(0.5 + \left(WL * \frac{TF(w)}{MaxTF}\right) + PL\right) + \left(0.5 + \left(WR * \frac{TF(w)}{MaxTF}\right) + PR\right) \quad (19)$$

更准确地说， WL[WR]测量与候选词（在左[右]侧）共同出现的不同词的数量与它共同出现的词的数量之间的比率。TF(w)是单词相对于所有单词中的最大频率 (MaxTF) 的频率，PL[PR]测量与候选单词（在左[右]侧）共同出现的不同单词的数量与 MaxTF 之间的比率。实际上，候选词越不重要，该特征的得分就越高。因此，类似的停止词很容易获得更高的分数。

Word DifSentence：量化候选词在不同句子中出现的频率。一个词在越多句子中出现，相对显得更加重要。见公式(20)：

$$W_{DifSentence} = \frac{SF(w)}{\#Sentences} \quad 20)$$

其中, SF(w)单词 w 出现的句子频率，也就是单词 w 出现的句子数。#Sentences 是文档中句子的总数。

计算每个单词的权重所用方法见公式(21)：

$$S(w) = \frac{W_{Rel} * W_{Position}}{W_{Case} + \frac{W_{Freq}}{W_{Rel}} + \frac{W_{DifSentence}}{W_{Rd}}} \quad (21)$$

因为候选关键词可以是单词也可以词组，所以我们设置了滑动窗口大小为 1、2、3 来设定关键词序列。另外，我们不考虑以停用词开头和结尾的连续序列。同样重要的是，对于候选关键词没有要求必须具有最小频率或句子频率。这意味着，我们可以将一个关键字视为重要或不重要的依次出现或者多次出现。然后，每个候选关键字将为分配一个最终形式的 S(kw)，这样分数越小，关键词就越有意义。见公式（22）：

$$S(kw) = \frac{\prod_{w \epsilon kw} S(w)}{TF(kw) * (1 + \sum_{w \epsilon kw} S(w)} \tag{22}$$

S(*kw*)是最大尺度为 3 的候选词的得分。

对于得到的所有关键词，我们基于提取的每个关键字 WikipediaAPI 和谷歌 CSE API 检索上下文，因为它们能提供可靠上下文的能力。

通过关键字选取进行的外部知识库的检索，我们可以获得正确的事实性论述。

之后使用语义熵的方法，将得到的事实论述与 LLM 回答的多个答案再次进行聚类计算语义熵。

3.3 幻觉解释模块

在当前的 LLM 黑盒幻觉检测研究领域，大多数的研究方法普遍聚焦于检测准确率的优化，缺乏对幻觉检测结果的解释。而对于 LLM 的使用者而言，他们不仅需要幻觉存在的二值判定，更亟需得到对幻觉的解释，用于对 LLM 的幻觉回答进行修正或者优化，以便将修正后的 LLM 回答应用于特定领域。

同时由于现有公开数据集缺乏细粒度幻觉标注（如错误类型、知识冲突位置等），直接训练解释模型面临数据稀缺挑战。受少样本提示[39]的启发，本项目提出一种**基于少样本提示的多模块协同幻觉解释框架**。其核心是通过整合检测阶段的中间结果与少样本提示技术，生成用户可理解的幻觉成因分析。

少样本提示是一种无需训练即可引导 LLM 完成特定任务的技术，其核心是通过在输入中提供少量示例来演示任务模式。如图 3-28 所示，模型在接收到任务描述“翻译英语到法语”后，通过示例快速学习映射规则，最终对新的输入“cheese”生成符合要求的输出。这种方法无需梯度更新，依赖示例的上下文学习能力，尤其适合数据稀缺场景，为本项目的幻觉解释模块提供了低资源实现路径。

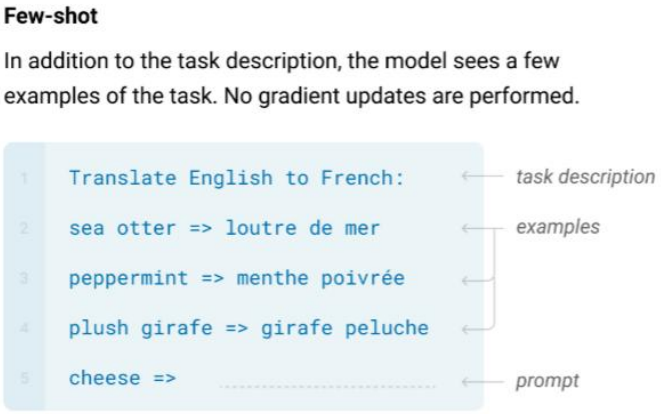


图 3-28 少样本提示示例

同时少样本提示通过提供少量上下文示例，显著提升了模型的任务准确性，如图 3-29 中 Few-shot 与 Zero-shot/One-shot 对比所示。少样本提示在不同参数规模的模型中均表现稳定，且无需额外训练即可实现性能跃升。

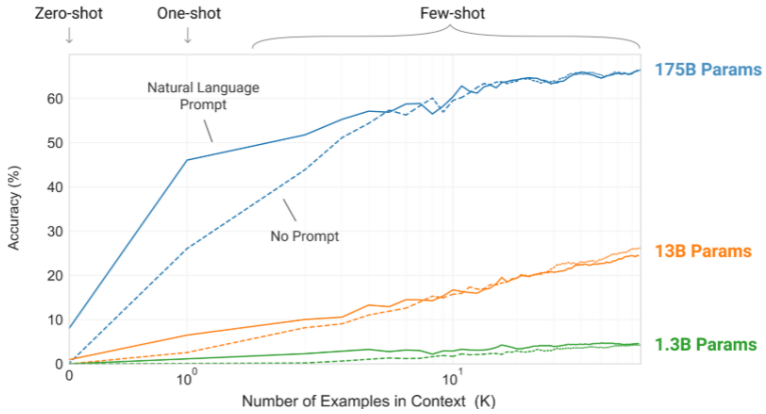


图 3-29 Few-shot与Zero-shot/One-shot对比

具体而言，本模块的幻觉解释任务包含三类核心方法，分别针对不同层级的幻觉检测需求：1.忠实性上下文分析解释；2.基于原子事实的语义采样对比解释；3.基于原子事实的知识冲突对比解释。

3.3.1 忠实性上下文分析解释

首先，针对忠实性幻觉检测模块标记为 Not-Faithful 的多个忠实性幻觉句子 $S = \{S_{h_1}, S_{h_2}, \ldots, S_{h_n}\}$，少样本学习提示$\mathcal{P}_{\text{faith}}$被构造为任务描述以及一系列示例的组合，任务描述为自然语言指令，说明分析目标，用τ_f表示；示例集表示为$\mathcal{E}_f = \{\text{Ex}_1, \ldots, \text{Ex}_m\}$。提示$\mathcal{P}_{\text{faith}}$可以被表示为：

$$\mathcal{P}_{\text{faith}} = (\tau_f, \mathcal{E}_f) \tag{23}$$

其中$\mathcal{E}_f$中的每个示例Ex_i定义为三元组:

$$Ex_i = (C_i, H_i, A_i) \tag{24}$$

C_i表示上下文背景，H_i是忠实性幻觉句子，A_i是对(C_i, H_i)的忠实性幻觉分析解释。

接下来，对每个S_{h_j}，将其与用户原始输入查询 Q 以及提示$\mathcal{P}_{\mathrm{faith}}$串联结合后输入$E_{LLM}$中，对于$E_{LLM}$生成的回答记作$A_j$,表示对于忠实性幻觉句子$S_{h_j}$在以用户原始输入查询 Q 为上下文背景下的分析解释。换句话说，提示$\mathcal{P}_{\mathrm{faith}}$、用户原始输入查询 Q 以及忠实性幻觉句子$S_{h_j}$输入 LLM 中,如式(25)所示：

$$A_j = E_{LLM}\left(\left[\mathcal{P}_{\mathrm{faith}}; Q, S_{h_j}\right]\right) \tag{25}$$

最终，经过上述流程得到忠实性幻觉解释集$\{(S_{h_j}, A_j, T)\}_{j=1}^{n}$。其中，我们采用$T \in \{0,1\}$来明确区分幻觉类型$\mathrm{T} = 0$表示忠实性幻觉，$T = 1$表示事实性幻觉。

3.3.2 基于原子事实的语义采样对比解释

首先，对于在事实性幻觉检测模块中初次检测为事实性幻觉的原子事实定义为:$\mathcal{F}_h = \{f_{h_1}, \ldots, f_{h_{n'}}\}$。在事实性幻觉检测模块检测过程中根据每个事实性幻觉原子事实f_{h_i}，重构 6 个可能以该原子事实为答案的问题，定义为:$Q(f_{h_i}) = \{q_1, \ldots, q_6\}$。对每个问题$q_\beta$产生包含$f_{h_i}$的候选答案集$\mathcal{R}_\beta$；通过语义聚类将$\mathcal{R}_\beta$划分为若干个语义类别$\{\mathcal{C}_{\beta 1}, \ldots, \mathcal{C}_{\beta\alpha}\}$，其中$\mathcal{C}_{\beta 1}$为包含幻觉原子事实$f_{h_i}$的语义类别。

接下来，从每个语义类别$\mathcal{C}_{\beta j}(j \geq 2)$中随机抽取一个回答$d_{\beta j} \in \mathcal{C}_{\beta j}$构成语义对比集合$\mathcal{D}_\beta = \{d_{\beta 2}, \ldots, d_{\beta\alpha}\}$。幻觉原子事实$f_{h_i}$的所有问题的语义采样对比集合记作$D_i = \bigcup_{\beta=1}^{6} \mathcal{D}_\beta$。

本方法的少样本学习提示$\mathcal{P}_{\mathrm{sem}}$与上类似地表示为(26)式：

$$\mathcal{P}_{\mathrm{sem}} = (\tau_s, \mathcal{E}_s) \tag{26}$$

其中τ_s表示任务描述，$\mathcal{E}_s$表示少样本提示中的示例集，$\mathcal{E}_s = \{\mathrm{Ex}_1, \ldots, \mathrm{Ex}_{m'}\}$，其中$\mathcal{E}_s$中的每个示例$\mathrm{Ex}_i$定义为三元组，如(27)式所示:

$$\mathrm{Ex}_i = \left(f_{h_i}, D_i, A_i\right) \tag{27}$$

其中f_{h_i}表示幻觉原子事实，D_i表示语义采样对比集合，A_i是对该幻觉原子事实的分析解释。

接着对$\mathcal{F}_h = \{f_{h_1}, \ldots, f_{h_{n'}}\}$中的每个幻觉原子事实$f_{h_j}$、该原子事实的语义采样

对比集合D_j以及提示$\mathcal{P}_{\text{sem}}$，串联结合后输入E_{LLM}中，得到对事实性幻觉原子事实f_{h_j}的分析解释A'_j，如式(28)所示:

$$A'_j = E_{\text{LLM}}\left(\left[\mathcal{P}_{\text{sem}}; f_{h_j}, D_j\right]\right) \tag{28}$$

最终经过对每一个f_{h_j}进行解释后，得到解释集$\{(\mathbf{S_{f_j}}, \mathbf{A'_j}, \mathbf{T})\}_{\mathbf{j=1}}^{\mathbf{n'}}$,其中$\boldsymbol{S_{f_j}}$**表示幻觉原子事实**$\boldsymbol{f_{h_j}}$**在初始 LLM 回答中所对应的句子**；T=1，表示事实性幻觉。

3.3.3 基于原子事实的知识冲突对比解释

针对于事实性幻觉检测模块第二次检测为幻觉的原子事实，定义为: $\mathcal{F}_t = \{f_{t_1}, \ldots, f_{t_{n''}}\}$。对于这些原子事实，类似地，其少样本提示如式(29)所示:

$$\mathcal{P}_{\text{know}} = (\tau_k, \mathcal{E}_k) \tag{29}$$

其中τ_k表示利用知识库中的知识与原子事实进行对比解释幻觉的任务描述，$\mathcal{E}_k$为示例集，$\mathcal{E}_k = \{\text{Ex}_1, \ldots, \text{Ex}_{m''}\}$。类似地，其中的$\text{Ex}_i$为三元组，如式(30)所示:

$$\text{Ex}_i = \left(f_{t_i}, K_i, A_i\right) \tag{30}$$

其中f_{t_i}为幻觉原子事实，K_i为相关短知识集，A_i为依据相关短知识集对幻觉原子事实的解释。

为了对第二次检测为幻觉的原子事实f_{t_j}进行解释，将原子事实f_{t_j}、提示$\mathcal{P}_{\text{know}}$以及在事实性幻觉检测模块中根据该原子事实$f_{t_j}$检索知识库并处理后的相关知识集$K_j$结合后输入$E_{LLM}$中，得到根据相关知识集对幻觉原子事实$f_{t_j}$的解释$A''_j$，如式(31)所示:

$$A''_j = E_{\text{LLM}}\left(\left[\mathcal{P}_{\text{know}}; f_{t_j}, K_j\right]\right) \tag{31}$$

最终经过对$\mathcal{F}_t = \{f_{t_1}, \ldots, f_{t_{n''}}\}$中的所有幻觉原子事实进行解释后，得到解释集$\{(\boldsymbol{S_{t_j}}, A''_j, \boldsymbol{T})\}_{\boldsymbol{j=1}}^{\boldsymbol{n''}}$，其中$\boldsymbol{S_{t_j}}$为幻觉原子事实$f_{t_j}$在初始 LLM 回答中所对应的句子；T=1，表示事实性幻觉。

最后，通过上述三种方法得到三个幻觉解释集$\{(S_{h_j}, A_j, T)\}_{j=1}^{n}$、$\{(\boldsymbol{S_{f_j}}, \boldsymbol{A'_j}, \boldsymbol{T})\}_{\boldsymbol{j=1}}^{\boldsymbol{n'}}$、$\{(\boldsymbol{S_{t_j}}, A''_j, \boldsymbol{T})\}_{\boldsymbol{j=1}}^{\boldsymbol{n''}}$。为了解决现有方法中幻觉解释分散的问题，设计如下综合幻觉解释合并算法，旨在整合不同类型的幻觉解释。该算法结合上述三个幻觉解释集，对检测出的幻觉句子进行去重和合并，确保相同句子的不同幻觉类型能够统一呈现。通过该方法，用户可以获得更加完整、直观的幻觉解释，

提升模型幻觉检测的可读性和实用性。

算法 2：综合幻觉解释合并算法

输入：$E_f = \{(S_{h_j}, A_j, T=0)\}_{j=1}^{n}$，$E_s = \{(S_{f_j}, A'_j, T=1)\}_{j=1}^{n'}$，$E_k = \{(S_{t_j}, A''_j, T=1)\}_{j=1}^{n''}$

输出：$E_c = \{(S_j, A_j^{\text{combined}}, T_j^{\text{combined}})\}$

1 Step 1: 初始化综合解释集

$E_c = \emptyset$

2 Step 2: 解释合并

3 **for** $(S, A, T) \in E_f \cup E_s \cup E_k$ **do**

4 Substep 1: 句子匹配

5 **if** $S \notin E_c$ **then**

6 $E_c[S] = (A, \{T\})$

7 **else**

8 $E_c[S] = (E_c[S][0] + '''' + A, E_c[S][1] \cup \{T\})$

9 Step 3: 生成最终解释集

$E_c^{\text{final}} = \{(S_j, A_j^{\text{combined}}, T_j^{\text{combined}}) \mid S_j \in E_c\}$

10 **Return** E_c^{final}

经过综合幻觉解释合并算法，得到综合幻觉解释集E_c^{final}。

第4章 系统实现

4.1 系统功能实现

该系统的前端功能利用 VUE 框架进行开发，其灵活性和高效性为用户提供了如原生应用般顺滑的界面体验。同时，VUE 框架的组件化开发模式使得前端代码易于维护和扩展，从而实现了系统的可持续发展。

后端功能则采用 Python 语言进行构建。通过 Django 框架，前后端之间的通信变得更加简洁高效，大大提升了系统的性能表现。同时，利用 MySQL 数据库存储用户数据和交互记录，为系统提供了稳定可靠的数据存储和管理。

Django 框架的工作流程如图 4-1 所示。当前后端需要进行信息交互时，Client 会主动产生一个请求，该请求可被 WSGI 服务器接收。当服务器接收到请求后，会激活 Django 应用中相应的中间件以做出响应。

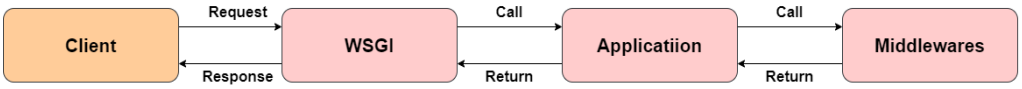


图 4-1 Django框架

4.2 系统用户界面

运行通用型 LLM 全幻觉检测与分析系统，进入主页面的界面如图 4-2 所示：

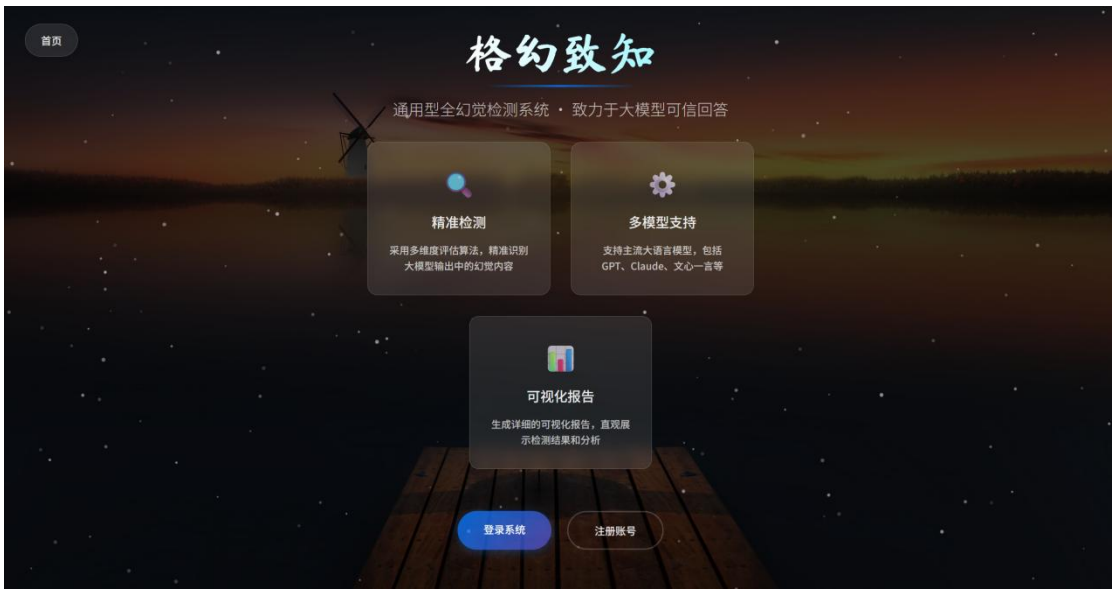


图 4-2 “格幻致知”主页面

点击“登录系统”或者“注册账号”进入注册登录页面，如图 4-3 所示：



图 4-3 “格幻致知”登录注册页面

注册登录后进入到幻觉检测页面，检测页面由左边框部分，对话部分，上边框部分组成。用户可以在上边框下滑栏部分切换内置大语言模型，在对话框输入与大语言模型对话。如图 4-4 所示：

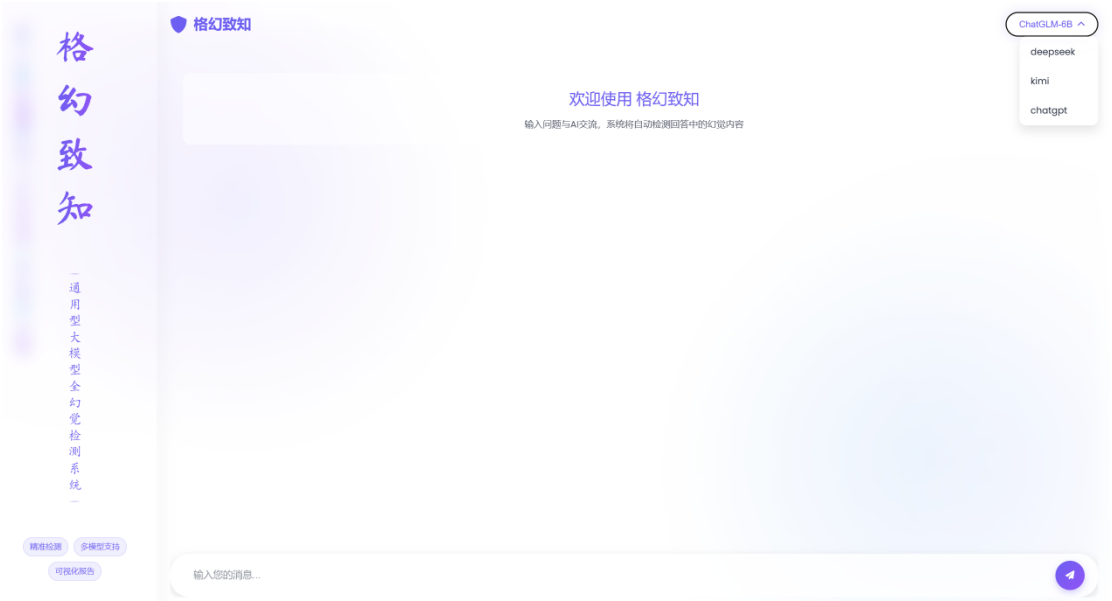


图 4-4 “格幻致知”幻觉检测页面

用户可以在下面对话栏输入与大语言模型进行对话，提问“太阳系有几大行星？，一句话说明”单命题回答示例如图 4-5 所示：

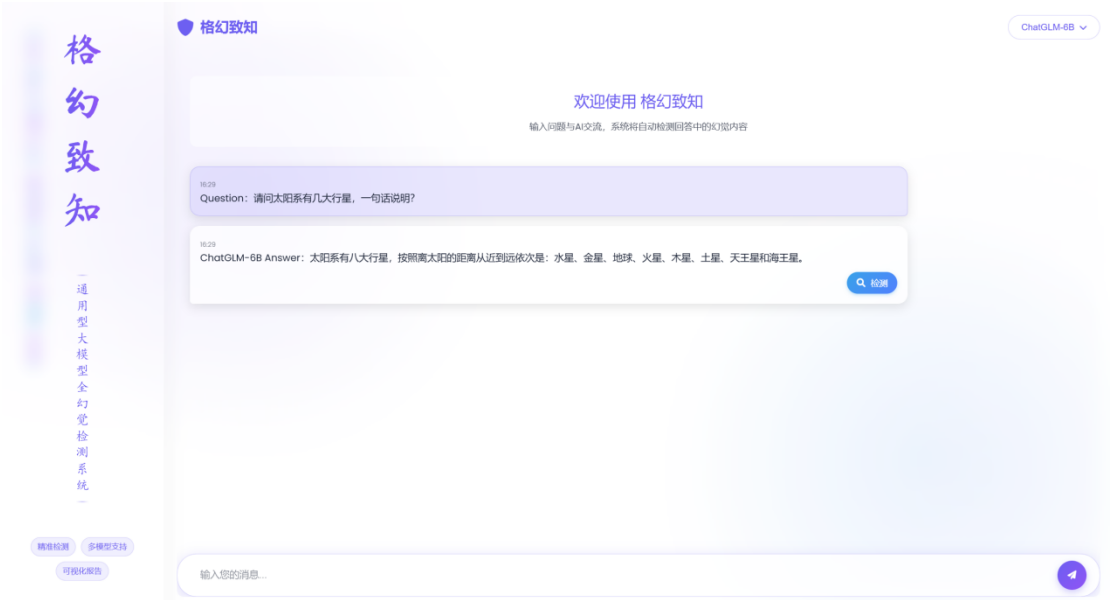


图 4-5 单命题回答示例

通过点击大语言模型 Answer 右侧“检测”按钮可以进行幻觉问题检测，并生成解释报告，单命题回答检测示例如图 4-6 所示：



图 4-6 单命题回答检测示例

忠实性幻觉回答示例，如图 4-7 所示：



图 4-7 忠实性幻觉回答示例

点击检测按钮后生成检测报告，忠实性幻觉回答检测如图 4-8 所示：



图 4-8 忠实性幻觉回答检测示例

多命题回答示例如图 4-9 所示：



图 4-9 多命题回答示例

点击检测按钮后生成检测报告，多命题回答幻觉检测如图 4-10 所示：



图 4-10 多命题幻觉回答检测示例

4.3 数据来源

QAGS：https://github.com/W4ngatang/qags/tree/master/data

FRANK：https://github.com/artidoro/frank/tree/main/data

TriviaQA：https://nlp.cs.washington.edu/triviaqa/

SQuAD：https://rajpurkar.github.io/SQuAD-explorer/

NQ-Open：https://huggingface.co/datasets/google-research-datasets/nq_open

4.4 数据训练

我们在 A100-SXM4-80GB 上进行模型训练和运行，一次完整的训练周期大约需要 2 个小时。训练过程中，采用了交叉验证来优化模型参数，并通过 TensorBoard 等工具监控训练进度和性能指标。

我们使用一张 A100-SXM4-80G 和 15 核 Xeon(R) Platinum 8358P CPU（120G 内存），运行所有脚本的时间约为 2 小时。同时，由于首次运行需要加载从 Hugging Face 加载 LLM，运行时间会更长。

4.5 改进过程

在模型开发初期，遇到了很多困难，如在使用语义熵计算时，对于某些未开源的 LLM 在生成文本时，不提供输出序列的概率分布（Token 的概率），这就无法使用传统的概率计算方法。为了实现系统的跨任意模型使用，我们不得不解决这一问题。故此，团队曾进行了大量的讨论和研究，最终我们采用了离散语义熵来估计语义不确定性，从而无需访问模型内部的参数，这种方法适用于任何生成模型，即使其内部概率不可知，只需能生成多样化的输出即可，成功解决了这一问题。

在参数调整上，我们也花费巨大，多次训练，多次调整参数。我们还采用了参数高效的调参方法，主要基于预训练模型 Electra，并通过适配器模块实现轻量级微调。此外，我们采用了学习率衰减、权重衰减等技术，以防止过拟合，提高模型的泛化能力。通过大量的实验，我们找到了一组较优的参数，使得模型在检测忠实性幻觉部分上取得了较好的效果。

在模型部署阶段，为确保系统的稳定性和安全性，我们对后端服务进行了压力测试和性能优化，并采用容器化技术来简化部署和维护过程。此外，我们开发了轻量级健康检查模块和自动化重启脚本，确保服务持续可用。为了提高系统的安全性，我们全面启用防 SQL 注入机制并实现 API 访问频率限制。最后，为了提高用户体验，还进行了多次用户测试，收集用户反馈，并据此进行界面的优化。

第5章 测试分析

5.1 测试数据集

为验证系统的有效性，本项目对每个任务（忠实性幻觉检测和事实性幻觉检测）分别使用了该任务专属的测试集，确保评估的针对性。同时在每个任务上，分别对比本系统和任务特异性基线，有效评估系统的能力。此外，在幻觉检测任务中，为更好地理解本系统提供的生成幻觉分析的质量，我们从每个评估数据集随机选择 50 份幻觉分析报告，由人类专家从以下几个方面进行评估 1）合理性，2）全面性，3）有效性，4）总体评价。

具体地，针对忠实性幻觉检测，我们使用了开源数据集 FRANK 进行测试，该数据集逐句标注，包含了大量模型生成的摘要数据，覆盖 2,250 篇由不同模型生成的新闻摘要（CNN/DM 和 XSum 数据集），每句由 3 位标注者独立标记忠实性错误。数据规模足够大，能够有效评估模型的性能和泛化能力。

针对事实性幻觉检测，为了全面评估验证系统在开放式生成领域的事实性检测能力，我们采用了多数据集融合的评估策略，整合了 TriviaQA、SQuAD 和 NQ-Open 三个问答数据集。这种多元化的数据融合方案不仅确保了系统在事实性幻觉检测任务上的高效性，更显著提升了模型在不同领域和场景下的泛化能力。

针对幻觉解释，我们从上述的两个数据集（FRANK 和融合后的数据集）中各随机挑取 150 份幻觉分析报告（共 300 份幻觉分析报告），能均衡覆盖上述两种任务（忠实性幻觉检测和事实性幻觉检测），避免因数据偏差导致结论片面。

5.2 测试过程

在忠实性幻觉检测模块构建机器学习模型的过程中，我们遵循了一个严格的三阶段流程，以确保模型的有效性和鲁棒性。首先，我们利用训练集 (QAGS) 对模型进行训练。这一阶段是模型学习的关键时期，通过不断调整模型参数，使模型能够从数据中捕捉到有用的特征，并逐步提高其在特定任务上的表现。

接下来，我们转向验证集 (FRANK) 阶段，这是模型调优的关键环节。在这一阶段，我们不再对训练集进行操作，以避免模型对训练数据过拟合。验证集帮助我们评估模型对新数据的适应能力，并允许我们微调模型参数，以提高其泛化

能力。通过这一过程，我们可以识别并减少模型的偏差和方差问题，确保模型既不过于复杂也不过于简单。

最后，我们使用独立的测试集来评估模型的最终性能。测试集是模型从未见过的数据，因此它能够提供模型在实际应用中表现的真实指标。在这一阶段，我们会计算各种性能指标，如平衡准确率、召回率、F1 分数等，以全面评估模型的效能。

对于事实性幻觉检测模块，我们提出的方法是一种无监督技术，直接基于模型的生成结果的概率或外部知识库检索并结合语义聚类计算熵值，不需要额外的训练数据和模型微调。测试对比阶段我们采用了多数据集融合的评估策略，覆盖了 TriviaQA、SQuAD 和 NQ-Open 多个数据集，并测试了 LLaMA 2，deepseek-chat 和 GPT 3.5 等不同规模的模型。在测试过程中，我们剥离数据集的上下文和参考答案，仅保留问题作为输入，迫使模型完全依赖内部知识生成答案。通过系统的对比试验验证事实性幻觉检测模块在检测事实性幻觉方面的有效性。

对于幻觉解释模块，为了确保幻觉解释模块生成的分析内容具有高质量和可靠性，我们使用严谨的人类评估的方法，并严格把控评估专家的资质与流程。在专家选择上，我们优先选择相关专业的学生团体，熟悉相关领域背景，拥有一定的专业知识基础和逻辑学基础。此外，拥有专业指导老师的大力支持，我们在评估前对所有的评审人员进行了培训，明确了评分维度的定义、边界及评分标准，最大程度上保证评判的一致性和客观性。尽管我们力求评估过程的科学性和严谨性，但受限于资源与时间成本，本次评估的样本规模相对有限，可能在一定程度上影响结论的普适性。此外，人类评估本身存在一定的主观性，尽管我们通过标准化流程尽可能减少偏差，但仍需在未来研究中结合更大规模的数据和自动化评估方法，以进一步提升结果的稳健性。

5.3 测试结果分析

表格 1 事实性幻觉测试结果对比

模型	LLaMA 2 Chat 7B		LLaMA 2 Chat13B		deepseek-chat		deepseek-reasoner		GPT-3.5-turbo	
检测方法	AUROC	AURAC	AUROC	AURAC	AUROC	AURAC	AUROC	AURAC	AUROC	AURAC
Naive Entropy[54]	0.69	0.70	0.70	0.72	0.71	0.73	0.72	0.74	0.68	0.70
Embedding[53]	0.67	0.67	0.68	0.71	0.70	0.73	0.70	0.72	-	-
P(True)[53]	0.70	0.71	0.71	0.73	0.72	0.74	0.73	0.75	0.70	0.71
SelfCheck-GPT[8]	0.74	0.75	0.75	0.77	0.76	0.78	0.77	0.78	0.74	0.75
DoLa[51]	0.72	0.73	0.73	0.74	0.75	0.76	0.75	0.78	-	-
FActScore[52]	**0.79**	0.81	0.77	0.80	0.79	0.81	0.82	0.84	0.75	0.79
Self-Contrast[11]	0.74	0.75	0.75	0.78	0.77	0.78	0.77	0.79	0.72	0.74
Semantic entropy[15]	0.76	0.76	0.77	0.79	0.78	0.79	0.78	0.80	-	-
ours-w/o-KB	0.74	0.75	0.74	0.76	0.77	0.78	0.77	0.79	0.76	0.75
ours	0.78	**0.82**	**0.83**	**0.84**	**0.84**	**0.86**	**0.87**	**0.88**	**0.81**	**0.82**

事实性幻觉测试对比结果如表格 1 所示。

在消融实验中，我们通过移除检索模块构建了对比方法(ours-w/o-KB)。实验数据表明，该方法在 AUROC 和 AURAC 两项指标上已显著优于多数基线方法，仅较语义熵方法存在微小差距（$\Delta<0.03$）。值得注意的是，当引入知识库检索迭代增强检测机制后，系统性能获得显著提升，AURAC 值进一步提升至 0.82-0.88 的优异水平，显著高于其他方法。这种结合不仅增强了语义熵的检测鲁棒性，还通过外部知识弥补了模型自身训练的局限性，使得 AURAC 提升尤为显著，更适合实际高风险应用场景。

在黑盒方法对比实验中，我们的方法也展现出显著的优势。经过对所有模型表现求平均值后，我们的方法以 0.826(AUROC)/0.844(AURAC)的综合表现位居首位，较次优的 FActScore 方法(0.784/0.810)综合提升 4.2%/3.4%。表现最差的是 Naive Entropy (0.700/0.718)，其 AUROC 和 AURAC 的值均是最低的。

表格 2 忠实性幻觉测试结果对比

模型	CNN/DM		Xsum	
检测方法	BACC	F1	BACC	F1
QAGS[55]	66.2	78.2	61.3	84.6
QUALS[56]	62.8	77.9	59.2	81.4
FACTCC[57]	70.1	78.9	58.1	74.4
HHEM	72.3	85.2	<u>75.2</u>	86.3
TRUE	<u>75.2</u>	<u>87.4</u>	**75.5**	<u>87.9</u>
Ours-w/o-adapter	72.3	86.8	68.4	86.6
Ours(pretrained structural and text adapters)	**76.0**	**87.9**	74.8	**88.2**

忠实性幻觉测试对比结果如表格 2 所示。

实验结果表明，在忠实性幻觉检测任务中，不同模型在 CNN/DM 和 XSum 数据集上的表现存在显著差异。其中，基于自然语言推理的 TRUE 模型在两项测试中均展现出较优性能，在 CNN/DM 和 XSum 上的 BACC 分别达到 75.2 和 75.5，F1 分数分别为 87.4 和 87.9，表明该模型在捕捉语义不一致性方面具有显著优势，尤其适用于高抽象文本，但需注意的是，TRUE 方法对计算资源的需求较高，影响其实用性。

HHEM 模型在 XSum 数据集上的表现与 TRUE 相当，显示其在处理高度抽象和压缩的短文本方面具有较强能力；然而，在 CNN/DM 上的性能略逊一筹。

本研究提出的方法在引入结构和文本适配器并进行预训练后，在 CNN/DM 上取得了最佳结果（BACC=76.0，F1=87.9），但在 XSum 上略低于 TRUE，但仍保持竞争力。相比之下，传统方法（QAGS、QUALS 和 FACTCC）整体表现较差，特别是在 XSum 数据集上，FACTCC 的 BACC 仅为 58.1。

综上所述，本研究提出的方法在忠实性幻觉检测任务中展现出较强的综合性能，能够根据不同类型文本的特点提供可行的解决方案。

表格 3 人工评价结果

指标	是否合理?		全面性				有效性					总体评价				
评审	No	Yes	1	2	3	4	1	2	3	4	5	1	2	3	4	5
事实性	88	**158**	26	31	**53**	40	12	35	**42**	40	21	11	13	49	**52**	25
忠实性	35	**192**	11	36	49	**54**	19	31	7	**48**	45	22	17	**54**	30	27
总计	123	**350**	37	67	**102**	94	31	66	49	**88**	66	33	30	**103**	82	52

人工评价结果（表格 3）表明，该方法在幻觉检测与解释方面具有显著优势。

在句子级评估中，74.0%的幻觉解释被判定为合理，证实了该方法能准确识别并合理解释大多数幻觉现象。

进一步分析报告级评估结果可见，有 65.3%的评估者对检测全面性给予正面评价（评分≥3 分），这意味着大多数的评估者认为我们的检测是没有遗漏的，说明该系统能有效覆盖各类幻觉情况。总体而言，有 79.0%的解释报告获得了 3 分及以上评价（总分 5 分），这一结果从两方面验证了系统的有效性：其一，在解释质量方面，系统能够生成符合人类认知逻辑的合理分析；其二，在检测效能方面，方法在保持高召回率的同时确保了解释的可信度。

综合上述主客观评估结果可以确认，本系统在所有任务中表现最为均衡和出色，不仅能够精准检测幻觉现象，还能提供具有实际应用价值的解释分析。

第6章 作品总结

6.1 作品特色与创新点

6.1.1 双模态图-文本联合编码架构

为提高生成式文本的忠实性检测精度，本项目在现有研究基础上进一步引入了基于双模态图-文本联合编码评估框架。该框架通过将上下文和 LLM 生成的回答分别编码为文本序列和 AMR 语义图双模态表示，再利用结构感知适配器和关系图卷积网络实现异构模态的深度交互。这种架构既能捕捉文本表面的词汇匹配，

又能通过语义图比对识别深层的概念关系错误。为兼顾性能和计算效率，本项目使用 Sentence-BERT 计算句子级上下文与生成回答的语义相似度，仅从上下文中选择与生成回答最相关的部分句子 (Top-K) 构建 AMR 语义图，显著提高了计算效率。同时，采用参数共享机制，文本和图编码器共享同一预训练模型主干，冻结原始参数，仅微调适配器的参数，能够在保持性能的同时大幅减少训练成本，实现了高效经济的模型部署。

6.1.2 内外部知识融合的迭代增强检测机制

在大模型事实性幻觉检测领域，本项目提出了一种创新的迭代增强检测机制，该机制巧妙地融合了语义熵分析与外部知识库的实时检索能力。首先，对大模型进行多次提问以获取多样化的回答。随后，根据回答的内容性质，将其分为单命题和多命题两类，并进行聚类处理。在此基础上，计算各类回答的语义熵，以此作为初步检测幻觉的依据。对于语义熵较高的回答，我们认为其可能包含不准确的信息，即存在幻觉现象。然后，对于语义熵较低，可能输出相同幻觉的回答，本项目采用 YAKE (Yet Another Keyword Extractor) 算法的思想进行关键词提取。提取出的关键词将作为检索的依据，通过 Wikipedia API 和谷歌 CSE API 等工具，检索相关的上下文信息，以获取正确的事实性论述。最后，为了确保检测结果的准确性，本项目将外部获取的事实性论述重新纳入语义熵模块中，进行迭代计算，如果回答不存在幻觉则再计算熵较低，如果存在幻觉，在和事实性论述一起计算时会呈现高的熵值。通过这种方法，本项目的检测机制不仅具备了依赖内部知识的普适性，能够适用于任何大模型，同时也通过依赖外部知识获得了较高的检测精度，为大模型事实性幻觉检测提供了一种新的解决方案。

6.1.3 多模块协同的少样本驱动幻觉解释架构

为提升大模型幻觉检测的可解释性与用户修正能力，本项目提出一种基于多模块协同的少样本驱动幻觉解释架构。该模块在忠实性与事实性幻觉检测模块的基础上，充分利用其中间输出信息，设计三类细粒度幻觉解释方法，分别针对不同类型与层级的幻觉句子，生成用户可理解的幻觉成因分析。具体包括：（1）忠实性上下文分析解释，利用原始查询对幻觉句子进行语义合理性解释；（2）基于原子事实的语义采样对比解释，通过对事实性幻觉检测模块中的重构问答进行语义聚类采样，揭示幻觉原子事实在多语义上下文中的响应偏离，反映出其在模型语义空间中的不稳定性与幻觉可能性；（3）基于原子事实的知识冲突对比

解释，通过将幻觉原子事实与知识库中的相关事实进行对照，挖掘潜在知识矛盾成因。三类方法均基于少样本提示技术构建，显著降低训练依赖，并提升解释生成的泛化能力。最终，项目设计综合幻觉解释合并算法，对三类解释结果进行去重与归一处理，支持对同一句子展示多类型幻觉成因，构建检测-解释闭环，显著增强了系统的可读性、解释性与实用性。

6.2 算法基础

项目团队成员在算法领域兼具扎实的理论基础与丰富的工程实践经验。系统掌握机器学习和深度学习的基本理论，而且能够熟练运用卷积神经网络 (CNN) 、循环神经网络 (RNN) 、图卷积网络 (GCN) 及 Transformer 等经典模型，并能针对实际场景优化 BERT、RAG 等前沿框架。在自然语言推理、文本分类及问答系统等任务中，不仅能够复现经典的算法，如 TextCNN、BiDAF 等，还能对这些算法进行创新和改进。

此外，团队成员持续关注学术前沿，广泛阅读顶级会议和期刊上的最新论文，如 ACL、EMNLP、NAACL 等，以确保知识体系与领域发展同步。通过深入研究，项目成员不断吸收和整合最新的研究成果，以强化在幻觉检测等复杂任务上的算法开发能力。

在幻觉检测这一特定领域，团队成员已经积累了丰富的经验。不仅熟悉如何处理和融合文本、图像和结构等多种模态的数据，还掌握了使用深度学习技术来提取特征、建模和分类的方法。通过不断的实验和验证，项目成员已经具备了设计和实现高效、鲁棒的幻觉检测算法的专业能力。

6.3 应用推广

在应用推广领域，项目团队兼具深厚的理论功底与丰富的实战经验。团队成员不仅深刻理解基础理论知识和前沿技术理论，更注重将复杂算法转化为直观易用的产品解决方案，确保技术创新真正落地并产生广泛影响。

团队在软件工程和系统架构设计方面也有深厚的背景，能够开发出高性能、高可靠的系统。熟悉多种编程语言和开发框架，如 Python、TensorFlow 和 PyTorch，使我们既能快速实现原型验证，又能高效推进产品迭代，为技术成果的产业化应用提供坚实保障。

6.4 作品展望

本项目的推行预期将有效缓解大语言模型的幻觉问题所引发的一系列社会问题，通过技术的力量，提高从事人员乃至公众对 AI 生成内容的甄别能力，使其能够更高效、更精准地评估模型输出的真实性与可靠性。这一举措不仅有助于净化网络信息生态，减少误导性内容的传播，更能构造一个更加可信、透明的大语言模型应用环境，从而推动网络空间的清朗化与健康发展，为社会和谐稳定提供坚实的技术支撑。

在后续的工作中，项目团队将持续深耕系统优化，重点提升模型在处理高复杂度、大规模对话任务的性能表现，确保技术方案在实际应用场景中发挥最大价值。同时，团队还考虑着力拓展系统在**多模态**领域的应用，针对当前大模型在生成式任务中普遍存在的**幻觉**、**偏见**和**语法错误**等一系列问题，提供创新性解决方案，从而全面提升多模态 AI 的可靠性与实用性。此外，项目团队还积极推动技术成果转化，探索系统架构的商业化和市场化路径，以期在幻觉检测领域形成可持续发展的商业模式。

6.5 技术路线方面

本项目采用了前沿的深度学习技术，结合多模块协同架构，形成了一套高效、可扩展的幻觉检测与解释方案。在技术实现上，团队通过深入探索和优化，确保各模块既能独立运行，又能无缝协作，实现准确、可靠的幻觉检测和分析。

针对忠实性幻觉检测，团队使用双模态编码，将语义图表示与文本编码相结合，利用结构感知适配器和图卷积网络实现深层次语义理解，同时通过参数共享机制确保模型的高效迁移能力。针对事实性幻觉检测，团队提出了语义熵与知识库互补增强的无监督方案，直接基于模型的生成结果的概率或外部知识库检索并结合语义聚类计算熵值，形成内外协同的验证体系，显著提升了高确定性幻觉检测的能力。在幻觉解释方面，项目基于少样本提示技术，生成用户可理解的幻觉成因分析，无需训练数据，仅利用检测中间结果和少样本提示实现轻量级解释。

通过以上技术的系统整合与应用，使系统能够精准识别各类复杂幻觉，同时保持对噪声和异常输入的高容错能力，为构建可信赖的大语言模型应用提供了坚实保障。

6.6 工作量方面

项目团队在半年时间内，投入了大量的时间和精力，完成了从数据处理、系统设计、系统开发到用户体验优化的全流程工作。在这一过程中，项目团队不仅学习了机器学习和深度学习的基本理论，还掌握了卷积神经网络 (CNN) 、图卷积网络 (GCN) 等基础技术，并在自然语言推理、文本分类及问答系统等领域进行了深入研究和实践。

此外，项目团队还参与了软件工程、前端开发、后端架构等方面的工作，以确保系统的高效稳定运行。通过持续的努力，项目团队积累了丰富的实践经验，为项目的成功奠定了坚实的基础。

6.7 数据和测试效果方面

为验证系统的有效性，本项目对每个任务分别使用了相对应的测试集，确保评估的针对性。同时在每个任务上，分别对比本系统和任务特异性基线，有效评估系统的能力。最后，为更好地验证本系统提供的幻觉分析报告的质量，我们使用了人类评估方法。在测试中，系统在对应的领域均展现出较高的准确率和鲁棒性，尤其是在句子级忠实性和事实性幻觉检测方面。在网页界面上，句子级幻觉检测结果和幻觉检测报告均以可视化的方式展现，使用户能够直观地判断模型输出的内容真实性和忠实性，有效提高用户对大模型的幻觉的辨识能力。

参考文献

[1] Ji, Ziwei et al. “Survey of Hallucination in Natural Language Generation.” ACM computing surveys 55.12 (2023): 1–38. Print.

[2] OpenAI. Introducing ChatGPT, 2023a. URL https://openai.com/blog/chatgpt.

[3] OpenAI. GPT-4 technical report. CoRR, abs/2303.08774, 2023b. URL https://arxiv.org/abs/2303.08774.

[4] “On Faithfulness and Factuality in Abstractive Summarization.” Proceedings of the conference - Association for Computational Linguistics. Meeting (2020): 1906–1919. Print.

[5] Dinan, Emily et al. Wizard of Wikipedia: Knowledge-Powered Conversational

agents (2018): n. pag. Print.

[6] “When Not to Trust Language Models: Investigating Effectiveness of Parametric and Non-Parametric Memories.” Proceedings of the conference - Association for Computational Linguistics. Meeting 1 (2023): 9802–9822. Print.

[7] Lee, Nayeon et al. Factuality Enhanced Language Models for Open-Ended Text Generation (2022): n. pag. Print.

[8] Manakul, P, A Liusie, and MJF Gales. SELFCHECKGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models (2023): n. pag. Print.

[9] Brewer, Neil et al. “Beliefs and Data on the Relationship between Consistency and Accuracy of Eyewitness Testimony.” Applied cognitive psychology 13.4 (1999): 297–313. Print.

[10] Granhag, Pär Anders, and Leif A. Strömwall. “Deception Detection Based on Repeated Interrogations.” Legal and criminological psychology 6.1 (2001): 85–101. Print.

[11] Zhang, Wenqi et al. Self-Contrast: Better Reflection Through Inconsistent Solving Perspectives (2024): n. pag. Print.

[12] Du, Yilun et al. Improving Factuality and Reasoning in Language Models through Multiagent Debate (2023): n. pag. Print.

[13] Wang, Xuezhi et al. Self-Consistency Improves Chain of Thought Reasoning in Language Models (2022): n. pag. Print.

[14] Mielke, Sabrina J. et al. “Reducing Conversational Agents’ Overconfidence Through Linguistic Calibration.” Transactions of the Association for Computational Linguistics 10 (2022): 857–872. Print.

[15] Farquhar, Sebastian et al. “Detecting Hallucinations in Large Language Models Using Semantic Entropy.” Nature (London) 630.8017 (2024): 625–630. Print.

[16] Fang, Yi et al. Counterfactual Debating with Preset Stances for Hallucination Elimination of LLMs (2024): n. pag. Print.

[17] Huang, Lei et al. “A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions.” ACM transactions on information systems 43.2 (2025): 1–55. Print.

[18] Farquhar, Sebastian et al. “Detecting Hallucinations in Large Language Models Using Semantic Entropy.” Nature (London) 630.8017 (2024): 625–630. Print.

[19] Nikitin, Alexander et al. Kernel Language Entropy: Fine-grained Uncertainty

Quantification for LLMs from Semantic Similarities (2024): n. pag. Print.

[20] MacKay, D. J. C. Information-based objective functions for active data selection. Neural Comput. 4, 590 – 604 (1992).

[21] Kadavath, S. et al. Language models (mostly) know what they know. Preprint at https://arxiv.org/abs/2207.05221 (2022).

[22] Lindley, D. V. On a measure of the information provided by an experiment. Ann. Math.Stat. 27, 986 – 1005 (1956).

[23] Holtzman, A., Buys, J., Du, L., Forbes, M. & Choi, Y. The curious case of neural text degeneration. In Proceedings of the International Conference on Learning Representations https://openreview.net/forum?id=rygGQyrFvH (2020).

[24] Fan, A., Lewis, M. & Dauphin, Y. Hierarchical neural story generation. In Proc. 56th Annual Meeting of the Association for Computational Linguistics (eds Gurevych, I. & Miyao, Y.) 889 – 898 (Association for Computational Linguistics, 2018).

[25] Culicover, P. W. Paraphrase generation and information retrieval from stored text. Mech.Transl. Comput. Linguist. 11, 78 – 88 (1968).

[26] Negri, M., Bentivogli, L., Mehdad, Y., Giampiccolo, D. & Marchetti, A. Divide and conquer:crowdsourcing the creation of cross-lingual textual entailment corpora. In Proc. 2011 Conference on Empirical Methods in Natural Language Processing 670 – 679 (Association for Computational Linguistics, 2011).

[27] Padó, S., Cer, D., Galley, M., Jurafsky, D. & Manning, C. D. Measuring machine translation quality as semantic equivalence: a metric based on entailment features. Mach. Transl. 23,181 – 193 (2009)

[28] Androutsopoulos, I. & Malakasiotis, P. A survey of paraphrasing and textual entailment methods. J. Artif. Intell. Res. 38, 135 – 187 (2010).

[29] MacCartney, B. Natural Language Inference (Stanford Univ., 2009).

[30] Schuster, T., Chen, S., Buthpitiya, S., Fabrikant, A. & Metzler, D. Stretching sentence-pair NLI models to reason over long documents and clusters. In Findings of the Association for Computational Linguistics: EMNLP 2022 (eds Goldberg, Y. et al.) 394 – 412 (Association for Computational Linguistics, 2022).

[31] Laura Banarescu, Claire Bonial, Shu Cai, Madalina Georgescu, Kira Griffitt, Ulf Hermjakob, Kevin Knight, Philipp Koehn, Martha Palmer, and Nathan Schneider. 2013. Abstract Meaning Representation for sembanking. In Proceedings of the 7th Linguistic Annotation Workshop and Interoperability with Discourse, pages 178–186, Sofia,

Bulgaria. Association for Computational Linguistics.

[32] Ribeiro, Leonardo F. R et al. FactGraph: Evaluating Factuality in Summarization with Semantic Graph Representations (2022): n. pag. Print.

[33] Hong, Jiaying et al. NCL-UoR at SemEval-2025 Task 3: Detecting Multilingual Hallucination and Related Observable Overgeneration Text Spans with Modified RefChecker and Modified SeflCheckGPT (2025): n. pag. Print.

[34] Hu, Xiangkun et al. RefChecker: Reference-based Fine-grained Hallucination Checker and Benchmark for Large Language Models (2024): n. pag. Print.

[35] Sataer, Yikemaiti et al. “Hierarchical Information Matters! Improving AMR Parsing with Multi-Granularity Representation Interactions.” Information processing & management 61.3 (2024): 103698. Print.

[36] Campos, R., Mangaravite, V., Pasquali, A., Jorge, A.M., Nunes, C., Jatowt, A. (2018). A Text Feature Based Automatic Keyword Extraction Method for Single Documents. In: Pasi, G., Piwowarski, B., Azzopardi, L., Hanbury, A. (eds) Advances in Information Retrieval. ECIR 2018. Lecture Notes in Computer Science, vol 10772. Springer, Cham.

[37] Schlichtkrull, Michael et al. Modeling Relational Data with Graph Convolutional Networks (2018): n. pag. Print.

[38] Houlsby, Neil et al. Parameter-Efficient Transfer Learning for NLP (2019): n. pag. Print.

[39] Brown, Tom B et al. Language Models are Few-Shot Learners (2020): n. pag. Print.

[40] Vaswani, Ashish et al. Attention Is All You Need (2017): n. pag. Print.

[41] Clark, Kevin et al. “ELECTRA: Pre-Training Text Encoders as Discriminators Rather Than Generators.” arXiv.org (2020): arXiv.org, 2020-03. Print.

[42] Ribeiro, Leonardo F. R, Yue Zhang, and Iryna Gurevych. Structural Adapters in Pretrained Language Models for AMR-to-text Generation (2021): n. pag. Print.

[43] Kim, Yekyung et al. FABLES: Evaluating faithfulness and content selection in book-length summarization (2024): n. pag. Print.

[44] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. BLEU: a method for automatic evaluation of machine translation. In Proceedings of the 40th Annual Meeting on Association for Computational Linguistics (ACL '02). Association for Computational Linguistics, USA, 311–318.

[45] Chin-Yew Lin. 2004. ROUGE: A Package for Automatic Evaluation of Summaries.

In Text Summarization Branches Out, pages 74–81, Barcelona, Spain. Association for Computational Linguistics.

[46] Liu, Yang et al. G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment (2023): n. pag. Print.

[47] Lewis, Patrick et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks (2020): n. pag. Print.

[48] Luo, Linhao et al. Reasoning on Graphs: Faithful and Interpretable Large Language Model Reasoning (2023): n. pag. Print.

[49] He, Pengcheng et al. DeBERTa: Decoding-enhanced BERT with Disentangled Attention (2020): n. pag. Print

[50] Pagnoni, Artidoro, Vidhisha Balachandran, and Yulia Tsvetkov. Understanding Factuality in Abstractive Summarization with FRANK: A Benchmark for Factuality Metrics (2021): n. pag. Print.

[51] Chuang, Yung-Sung et al. DoLa: Decoding by Contrasting Layers Improves Factuality in Large Language Models (2023): n. pag. Print.

[52] Min, Sewon et al. FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation (2023): n. pag. Print.

[53] Kadavath, Saurav et al. Language Models (Mostly) Know What They Know (2022): n. pag. Print.

[54] Xiao, Yijun, and William Yang Wang. On Hallucination and Predictive Uncertainty in Conditional Language Generation (2021): n. pag. Print.

[55] “Asking and Answering Questions to Evaluate the Factual Consistency of Summaries.” Proceedings of the conference - Association for Computational Linguistics. Meeting (2020): 5008–5020. Print.

[56] Nan, Feng et al. Improving Factual Consistency of Abstractive Summarization via Question Answering (2021): n. pag. Print.

[57] Kryściński, Wojciech et al. Evaluating the Factual Consistency of Abstractive Text Summarization (2019): n. pag. Print.

[58] DeepSeek-AI et al. DeepSeek LLM: Scaling Open-Source Language Models with Longtermism (2024): n. pag. Print.

[59] Wang, Alex, Kyunghyun Cho, and Mike Lewis. Asking and Answering Questions to Evaluate the Factual Consistency of Summaries (2020): n. pag. Print.

[60] Pagnoni, Artidoro, Vidhisha Balachandran, and Yulia Tsvetkov. Understanding

Factuality in Abstractive Summarization with FRANK: A Benchmark for Factuality Metrics (2021): n. pag. Print.

[61] Joshi, Mandar et al. TriviaQA: A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension (2017): n. pag. Print.

[62] Rajpurkar, Pranav et al. SQuAD: 100,000+ Questions for Machine Comprehension of Text (2016): n. pag. Print.

[63] Lee, Kenton, Ming-Wei Chang, and Kristina Toutanova. Latent Retrieval for Weakly Supervised Open Domain Question Answering (2019): n. pag. Print.

[64] 石雨昕. 中国工程院院士沈昌祥：完全消除大模型“幻觉”等安全风险较难实现 需强化构建数字经济主动免疫保障体系[N]. 每日经济新闻,2024-12-09(036).DOI:10.28571/n.cnki.nmrjj.2024.003584.

[65] 澎湃新闻. 杭州 3 月 1 日取消限行？媒体称系 ChatGPT 所写，警方将发布调查结果[EB/OL]. (2023-02-17)[2025-3-20].
https://www.thepaper.cn/newsDetail_forward_21953693

[66] Sara Merken. Lawyers in Walmart lawsuit admit AI 'hallucinated' case citations[EB/OL]. (2025-2-10)[2025-3-20].
https://www.reuters.com/legal/legalindustry/lawyers-walmart-lawsuit-admit-ai-hallucinated-case-citations-2025-02-10/